



دانشکده فنی و مهندسی

پیش‌بینی جریان ترافیک وسایل نقلیه هوشمند با استفاده از الگوریتم بازسازی با تقویت گرادیان (XGBoost)

پایان‌نامه یا رساله برای دریافت درجه کارشناسی ارشد
در رشته مهندسی کامپیوتر گرایش نرم افزار

نام دانشجو
محمدعلی فلاح زاده راسته کناری

استاد راهنما:
دکتر قباد زرین‌چیان

شهریور ماه ۱۴۰۴



دانشکده فنی و مهندسی

پیش‌بینی جریان ترافیک وسایل نقلیه هوشمند با استفاده از الگوریتم بازسازی با تقویت گرادیان (XGBoost)

پایان‌نامه یا رساله برای دریافت درجه کارشناسی ارشد
در رشته مهندسی کامپیوتر گرایش نرم افزار

نام دانشجو:
محمدعلی فلاح زاده

استاد راهنما:
دکتر قباد زرین‌چیان

شهریور ماه ۱۴۰۴

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

تقدیم به:

با نهایت احترام و افتخار،
این پایان‌نامه را تقدیم می‌کنم به

روح پدر عزیزم که یاد و نامش همواره الهام‌بخش صبر و استقامت در مسیر زندگی‌ام بوده
است.

مادرم، که دعای خیر و حمایت بی‌دریغش چراغ راه من در تمام مراحل زندگی و تحصیل
بوده است.

تشکر و قدردانی:

بر خود لازم می‌دانم صمیمانه‌ترین سپاس‌های خویش را تقدیم نمایم به استاد راهنمای محترم، جناب آقای دکتر ...، که با راهنمایی‌های ارزشمند، دلسوزانه و دقیق خود همواره چراغ راه این پژوهش بودند. همچنین از استادان بزرگوار و اعضای محترم هیئت داوران که با نکته‌سنجی، دقت علمی و راهنمایی‌های سازنده خود زمینه ارتقای کیفیت این تحقیق را فراهم نمودند، کمال قدردانی را دارم.

از تمامی اساتید عزیزم در طول دوران تحصیل که با دانش و تجربه خود، مسیر علم‌آموزی را برایم هموار کردند، نیز صمیمانه سپاسگزارم.

در پایان، از خانواده گران‌قدرم که با حمایت‌های بی‌دریغ، دعای خیر و صبوری همیشگی همراه و پشتیبان من بوده‌اند، صمیمانه قدردانی می‌کنم.

چکیده

پیش‌بینی دقیق جریان ترافیک به‌عنوان یکی از چالش‌های اساسی در سیستم‌های حمل‌ونقل هوشمند، نقشی کلیدی در بهبود مدیریت ترافیک شهری، کاهش زمان سفر و ارتقای ایمنی جاده‌ها دارد. با توجه به ماهیت پیچیده، غیرخطی و وابسته به زمان و مکان داده‌های ترافیکی، استفاده از مدل‌های یادگیری ماشین و یادگیری عمیق می‌تواند دقت پیش‌بینی را به‌طور چشمگیری افزایش دهد.

هدف اصلی این پایان‌نامه، ارائه رویکردی دقیق و کارآمد برای پیش‌بینی جریان ترافیک در سیستم‌های حمل‌ونقل هوشمند است، به‌گونه‌ای که بتوان با کاهش خطا و افزایش پایداری مدل، مدیریت ترافیک شهری را بهبود بخشید. در همین راستا، از داده‌های واقعی دیتاست METR-LA شامل اطلاعات سرعت وسایل نقلیه جمع‌آوری‌شده توسط حسگرهای مستقر در شبکه جاده‌ای شهر لس‌آنجلس استفاده گردید. برای مدل‌سازی و پیش‌بینی جریان ترافیک، ابتدا مدل‌های LSTM و XGBoost به‌صورت جداگانه آموزش داده شدند و سپس یک مدل ترکیبی مبتنی بر تلفیق توانایی استخراج وابستگی‌های زمانی در LSTM و قدرت تعمیم XGBoost طراحی و پیاده‌سازی شد.

نتایج آزمایش‌ها نشان داد که مدل ترکیبی پیشنهادی عملکرد بهتری نسبت به مدل‌های منفرد داشته است؛ به‌گونه‌ای که مقدار MSE از ۳,۴۲ در مدل LSTM و ۳,۱۵ در مدل XGBoost به ۲,۸۷ در مدل ترکیبی کاهش یافت (حدود ۱۶٪ بهبود). همچنین مقدار MAE از (LSTM) ۱,۴۸ و (XGBoost) ۱,۳۹ به ۱,۲۱ در مدل ترکیبی رسید (حدود ۱۸٪ بهبود). این یافته‌ها بیانگر آن است که بهره‌گیری از رویکردهای ترکیبی می‌تواند راهکاری مؤثر برای مواجهه با پیچیدگی‌ها و ناهمگنی داده‌های ترافیکی در کاربردهای واقعی باشد.

واژه‌های کلیدی: پیش‌بینی جریان ترافیک، سیستم حمل‌ونقل هوشمند، LSTM، XGBoost، مدل ترکیبی

فهرست مطالب

۱	فصل ۱: مقدمه
۲	۱-۱- مقدمه
۲	۱-۲- بیان مسئله
۲	۱-۳- اهمیت و ضرورت تحقیق
۳	۱-۴- کاربردهای عملی و سناریوهای هدف
۳	۱-۵- اهداف تحقیق
۳	۱-۶- اهداف عملیاتی
۴	۱-۷- پرسشهای پژوهش
۴	۱-۸- قلمرو و دامنه تحقیق
۵	۱-۹- تعاریف مفهومی و عملیاتی کلیدی
۶	۱-۱۰- ساختار پایان نامه
۷	فصل ۲: مروری بر منابع
۸	۲-۱- مقدمه
۹	۲-۲- مفاهیم پایه
۹	۲-۲-۱- سیستم حمل و نقل هوشمند (ITS)
۹	۲-۲-۲- جریان ترافیک و پیشبینی آن
۱۰	۲-۲-۳- یادگیری ماشین (ML)
۱۰	۲-۲-۴- یادگیری عمیق (DL)
۱۱	۲-۲-۵- الگوریتم XGBoost و مدل‌های ترکیبی
۱۱	۲-۳- روش‌های یادگیری مورد استفاده در پیشبینی جریان ترافیک
۱۲	۲-۳-۱- مدل‌های آماری سنتی
۱۲	۲-۳-۲- روش‌های یادگیری ماشین (ML)
۱۳	۲-۳-۳- روش‌های یادگیری عمیق (DL)
۱۳	۲-۳-۴- مدل‌های ترکیبی و ساختارهای پیشرفته
۱۵	۲-۴- مطالعات داخلی
۱۹	۲-۵- مطالعات خارجی
۲۳	۲-۶- جمع بندی مطالعات و شکاف‌های پژوهشی
۲۴	۲-۷- جمع بندی فصل
۲۶	فصل ۳: روش تحقیق
۲۷	۳-۱- مقدمه
۲۸	۳-۲- تعریف مسئله و ساختار کلی مدل پیشنهادی
۲۸	۳-۲-۱- تعریف دقیق مسئله
۲۸	۳-۲-۲- ساختار کلی مدل پیشنهادی
۳۰	۳-۲-۳- دیاگرام کلی مدل پیشنهادی
۳۰	۳-۳- معرفی داده‌ها و ویژگی‌های مورد استفاده
۳۰	۳-۳-۱- معرفی دیتاست METR-LA
۳۱	۳-۳-۲- آمار توصیفی داده‌ها
۳۲	۳-۳-۳- ساختار داده‌ها
۳۲	۳-۳-۴- داده‌های گمشده نویزی
۳۳	۳-۳-۵- انتخاب ویژگی‌ها
۳۳	۳-۳-۶- آماده‌سازی نهایی داده‌ها

۳۴	۳-۴- پیش پردازش داده ها
۳۵	۳-۵- طراحی مدل پیشنهادی
۳۵	۳-۵-۱- معماری مدل ترکیبی
۳۵	۳-۵-۲- طراحی مدل LSTM
۳۷	۳-۵-۳- طراحی مدل XGBoost
۳۸	۳-۵-۴- طراحی مدل ترکیبی (LSTM + XGBoost)
۳۹	۳-۵-۵- مراحل طراحی و پیاده سازی
۴۰	۳-۵-۶- مزایای ساختار پیشنهادی
۴۰	۳-۶- معیارهای ارزیابی
۴۲	۳-۷- جمع بندی فصل

فصل ۴: نتایج و تفسیر آنها

۴۴	۴-۱- مقدمه
۴۵	۴-۲- پیاده سازی مدل
۴۵	۴-۲-۱- آماده سازی داده ها
۴۶	۴-۲-۲- پیاده سازی مدل LSTM
۴۷	۴-۲-۳- پیاده سازی مدل XGBoost
۵۰	۴-۲-۴- پیاده سازی مدل ترکیبی
۵۱	۴-۳- ارزیابی و مقایسه عملکرد مدل ها
۵۱	۴-۳-۱- جدول مقایسه ای عملکرد مدل ها
۵۱	۴-۳-۲- نمودار مقایسه ای
۵۳	۴-۴- جمع بندی فصل

فصل ۵: جمع بندی و پیشنهادها

۵۵	۵-۱- مقدمه
۵۵	۵-۲- جمع بندی نتایج
۵۵	۵-۳- تحلیل مزایا و محدودیت ها
۵۶	۵-۴- پیشنهادات برای تحقیقات آینده
۵۶	۵-۵- جمع بندی نهایی

مراجع

فهرست اشکال

۴۷	شکل (۱-۴) نمودار تغییرات MSE و MAE مدل LSTM در طول آموزش
۴۹	شکل (۲-۴) نمودار اهمیت ویژگی ها در مدل XGBoost
۴۹	شکل (۳-۴) منحنی یادگیری مدل XGBoost بر اساس معیار MAE
۵۱	شکل (۴-۴) پیش بینی مدل ترکیبی در مقابل مقادیر واقعی
۵۲	شکل (۵-۴) مقایسه مدل ها از نظر خطای MSE
۵۲	شکل (۶-۴) مقایسه مدل ها از نظر خطای MAE

فهرست جداول

جدول (۱-۲)	مقایسه رویکردهای ترکیبی در پیش‌بینی جریان ترافیک	۱۵
جدول (۲-۲)	مقایسه مقالات منتخب داخلی	۱۸
جدول (۳-۲)	مقایسه مقالات منتخب خارجی	۲۲
جدول (۱-۴)	مقایسه عملکرد مدل‌ها	Error! Bookmark not defined.
جدول (۲-۴)	مقایسه عملکرد مدل‌ها	۵۱

فصل ۱ :

مقدمه

۱-۱- مقدمه

با رشد روزافزون جمعیت شهری و گسترش زیرساخت‌های حمل‌ونقل، مدیریت جریان ترافیک به یک چالش حیاتی در کلان‌شهرها تبدیل شده است. [۱] ازدحام ترافیکی نه تنها منجر به افزایش زمان سفر و مصرف سوخت می‌شود، بلکه تأثیرات منفی بر کیفیت هوا و سلامت روان شهروندان نیز دارد. [۲] در این راستا، استفاده از روش‌های نوین مبتنی بر هوش مصنوعی و یادگیری ماشین برای پیش‌بینی دقیق جریان ترافیک، به عنوان راهکاری کارآمد و آینده‌نگرانه مطرح شده است. [۳] این پژوهش تلاش دارد با ترکیب دو مدل قدرتمند LSTM^۱ و XGBoost^۲، سیستمی دقیق و قابل اعتماد برای پیش‌بینی جریان ترافیک ارائه دهد.

۱-۲- بیان مسئله

پیش‌بینی جریان ترافیک مسئله‌ای پیچیده و پویا است که نیازمند مدل‌هایی با قابلیت درک هم‌زمان وابستگی‌های زمانی و روابط غیرخطی میان متغیرها می‌باشد. [۱] مدل‌های سنتی نظیر رگرسیون یا شبکه‌های عصبی ساده اغلب در مواجهه با حجم بالای داده‌های ترافیکی و تغییرپذیری الگوها دچار ضعف عملکرد می‌شوند. [۲] در مقابل، مدل LSTM توانایی بالایی در استخراج وابستگی‌های زمانی دارد و الگوریتم XGBoost در شناسایی الگوهای غیرخطی و مقابله با داده‌های گمشده عملکرد درخشانی نشان داده است. بنابراین مسئله اصلی این تحقیق طراحی و ارزیابی مدلی ترکیبی است که بتواند از نقاط قوت هر دو روش بهره‌برداری کرده و دقت پیش‌بینی جریان ترافیک را افزایش دهد.

۱-۳- اهمیت و ضرورت تحقیق

با توجه به روند فزاینده شهرنشینی، مدیریت هوشمند ترافیک به یکی از اولویت‌های اساسی در شهرهای مدرن تبدیل شده است. ارائه پیش‌بینی‌های دقیق و به‌موقع از وضعیت ترافیک می‌تواند زمان سفر را کاهش دهد، بهره‌برداری از زیرساخت‌های جاده‌ای را بهینه کند و در کاهش مصرف سوخت و آلاینده‌ها مؤثر باشد. علاوه بر این، سامانه‌های حمل‌ونقل هوشمند مبتنی بر پیش‌بینی (مانند مسیریابی پویا، زمان‌بندی تطبیقی چراغ‌ها، و هشدارهای بلادرنگ) می‌توانند کیفیت خدمت‌رسانی را ارتقا داده و کنترل ترافیک را هدفمندتر کنند. از این رو، طراحی مدل‌های ترکیبی

^۱ Long Short-Term Memory

^۲ Extreme Gradient Boosting

پیشرفته برای دقت بیشتر در پیش‌بینی جریان ترافیک اهمیت بالایی دارد. [۳], [۵], [۶]

۴-۱- کاربردهای عملی و سناریوهای هدف

- مسیریابی پویا و مدیریت تقاضا: پیشنهاد مسیرهای جایگزین و توزیع بار ترافیک بر اساس پیش‌بینی کوتاه‌مدت.
- کنترل تطبیقی چراغ‌های راهنمایی: تنظیم زمان‌بندی چراغ‌ها متناسب با حجم و سرعت جریان ترافیک.
- مدیریت رخدادهای و شرایط غیرعادی: واکنش سریع به حوادث، تعمیرات و شرایط آب‌وهوایی با اتکا به پیش‌بینی‌های لحظه‌ای.
- پشتیبانی تصمیم در مراکز کنترل ترافیک: تخصیص بهینه منابع و خدمات امدادی بر اساس پیش‌بینی‌های آینده.
- اطلاع‌رسانی به کاربران نهایی: ارتقای ایمنی و تجربه سفر از طریق سامانه‌های ناوبری هوشمند.

۵-۱- اهداف تحقیق

هدف کلی:

- طراحی و پیاده‌سازی یک مدل ترکیبی مبتنی بر LSTM و XGBoost برای پیش‌بینی جریان ترافیک.

اهداف ویژه:

۱. بررسی عملکرد مدل LSTM در پیش‌بینی جریان ترافیک.
۲. بررسی عملکرد مدل XGBoost در همین حوزه.
۳. تحلیل دقت مدل ترکیبی در مقایسه با مدل‌های منفرد.
۴. ارزیابی مزایا و محدودیت‌های رویکرد ترکیبی.
۵. ارائه پیشنهادهایی برای توسعه مدل در تحقیقات آینده.

۶-۱- اهداف عملیاتی

- گردآوری و پیش‌پردازش داده‌های ترافیک (دیتاست METR-LA) شامل پاک‌سازی،

بازسازی داده‌های گمشده و نرمال‌سازی

- طراحی و پیاده‌سازی مدل LSTM برای استخراج الگوهای زمانی
- طراحی و پیاده‌سازی الگوریتم XGBoost برای مدل‌سازی روابط غیرخطی
- توسعه مدل ترکیبی LSTM-XGBoost و مقایسه عملکرد آن با مدل‌های منفرد
- تحلیل نتایج با معیارهای MAE، MSE، RMSE و R^2
- ارائه کاربردهای عملی مدل پیشنهادی در مدیریت ترافیک هوشمند

۷-۱- پرسش‌های پژوهش

۱. آیا مدل LSTM به‌تنهایی قادر به پیش‌بینی دقیق جریان ترافیک است؟
۲. عملکرد الگوریتم XGBoost در مقایسه با LSTM چگونه است؟
۳. آیا ترکیب LSTM و XGBoost منجر به افزایش دقت و پایداری پیش‌بینی می‌شود؟
۴. چه معیارهایی برای ارزیابی مدل ترکیبی مناسب‌تر است؟
۵. محدودیت‌های مدل پیشنهادی در مواجهه با داده‌های گمشده و پرترافیک چیست؟
۶. ظرفیت‌های مدل ترکیبی برای استفاده در سامانه‌های واقعی حمل‌ونقل هوشمند کدام‌اند؟

۸-۱- قلمرو و دامنه تحقیق

به‌منظور مشخص‌سازی حدود و چارچوب پژوهش، قلمرو تحقیق در سه بعد مکانی، زمانی و مفهومی تعریف می‌شود:

۱. قلمرو مکانی:

این تحقیق بر اساس داده‌های ترافیکی شهر لس‌آنجلس (دیتاست METR-LA) انجام شده است. هرچند داده‌ها مربوط به یک کلان‌شهر خارجی هستند، اما ساختار شبکه‌ای و رفتار ترافیکی آن، شباهت زیادی به کلان‌شهرهایی همچون تهران و مشهد دارد و می‌تواند مبنایی برای تعمیم به شرایط مشابه باشد.

۲. قلمرو زمانی:

داده‌های مورد استفاده مربوط به بازه‌ی زمانی مارس تا ژوئن سال ۲۰۱۲ هستند که در بازه‌های ۵ دقیقه‌ای جمع‌آوری شده‌اند. این بازه زمانی امکان تحلیل الگوهای کوتاه‌مدت و میان‌مدت ترافیک را فراهم می‌سازد.

۳. قلمرو مفهومی:

این تحقیق بر پیش‌بینی سرعت جریان ترافیک در شبکه‌ی جاده‌ای متمرکز است. دامنه پژوهش بر استفاده از مدل‌های یادگیری ماشین (XGBoost) و یادگیری عمیق (LSTM) و ترکیب آن‌ها محدود می‌شود. سایر عوامل تأثیرگذار نظیر شرایط آب و هوایی، رویدادهای غیرعادی یا داده‌های چندمنبعی در این نسخه از تحقیق لحاظ نشده و می‌تواند موضوع پژوهش‌های آتی قرار گیرد.

۹-۱. تعاریف مفهومی و عملیاتی کلیدی

به منظور جلوگیری از هرگونه ابهام و ایجاد درک مشترک از مفاهیم اصلی، تعاریف زیر در این تحقیق ارائه می‌شوند:

۱. سیستم‌های حمل‌ونقل هوشمند (ITS)^۱:

مجموعه‌ای از فناوری‌ها، الگوریتم‌ها و زیرساخت‌ها که با بهره‌گیری از داده‌های لحظه‌ای و ابزارهای تحلیل پیشرفته، مدیریت کارآمدتر جریان ترافیک، افزایش ایمنی و کاهش مصرف انرژی را هدف قرار می‌دهند.

۲. جریان ترافیک^۲:

به تعداد وسایل نقلیه عبوری از یک مقطع مشخص در واحد زمان گفته می‌شود. در این تحقیق، جریان ترافیک عمدتاً با شاخص سرعت متوسط وسایل نقلیه در بازه‌های زمانی ۵ دقیقه‌ای بیان شده است.

۳. پیش‌بینی جریان ترافیک^۳:

فرآیند تخمین سرعت یا حجم ترافیک در بازه‌های زمانی آینده بر اساس داده‌های گذشته و الگوهای آماری یا الگوریتمی.

۴. LSTM:

یک نوع شبکه عصبی بازگشتی عمیق است که قادر به مدل‌سازی وابستگی‌های بلندمدت در داده‌های سری‌زمانی بوده و در این تحقیق برای استخراج ویژگی‌های زمانی داده‌های ترافیکی به‌کار گرفته شده است.

^۱ Intelligent Transport System

^۲ Traffic Flow

^۳ Traffic Flow Prediction

۵. XGBoost:

یکی از قدرتمندترین الگوریتم‌های یادگیری ماشین مبتنی بر درخت تصمیم است که به دلیل سرعت بالا، دقت زیاد و توانایی مقابله با داده‌های گمشده، در این پژوهش به‌عنوان مدل مکمل LSTM استفاده شده است.

۶. مدل ترکیبی^۱:

مدلی است که در آن خروجی یا ویژگی‌های استخراج‌شده از یک الگوریتم به‌عنوان ورودی الگوریتم دیگر مورد استفاده قرار می‌گیرد. در این تحقیق، ترکیب LSTM و XGBoost به‌منظور افزایش دقت پیش‌بینی جریان ترافیک پیاده‌سازی شده است.

۱۰-۱. ساختار پایان‌نامه

این پایان‌نامه در پنج فصل تنظیم شده است:

- فصل اول: کلیات تحقیق شامل بیان مسئله، اهمیت موضوع، اهداف و ساختار پژوهش.
- فصل دوم: مرور ادبیات تحقیق و مطالعات انجام‌شده در حوزه پیش‌بینی جریان ترافیک.
- فصل سوم: روش تحقیق شامل معرفی داده‌ها، مراحل پیش‌پردازش، طراحی مدل‌ها و ابزارهای مورد استفاده.
- فصل چهارم: پیاده‌سازی مدل‌ها و تحلیل نتایج عددی و نموداری.
- فصل پنجم: جمع‌بندی نتایج، مقایسه با مطالعات پیشین و ارائه پیشنهادهایی برای تحقیقات آینده.

^۱ Hybrid Model

فصل ۲ :

مروري بر منابع

۲-۱- مقدمه

پیش‌بینی جریان ترافیک، یکی از حوزه‌های حیاتی در توسعه سیستم‌های حمل‌ونقل هوشمند (ITS) به شمار می‌رود و نقش بسزایی در مدیریت ترافیک، کاهش ازدحام، صرفه‌جویی در زمان سفر، کاهش مصرف سوخت و بهبود کیفیت هوا دارد. [۱]، [۳]، [۴]، [۵] این موضوع به‌ویژه با ظهور فناوری‌های نوینی همچون اینترنت وسایل نقلیه (IoV)، ارتباطات X۲V و شبکه‌های حمل‌ونقل هوشمند، اهمیت بیشتری یافته است. [۱]، [۶]، [۷]، [۸] در این راستا، روش‌های متعددی برای پیش‌بینی ترافیک پیشنهاد شده‌اند که از مدل‌های آماری کلاسیک گرفته تا الگوریتم‌های یادگیری ماشین و شبکه‌های عصبی عمیق را دربرمی‌گیرند. [۱]، [۸] در سال‌های اخیر، افزایش حجم داده‌های ترافیکی ناشی از گسترش اینترنت اشیاء^۲، خودروهای متصل^۳ و سیستم‌های مبتنی بر V۲X^۴، موجب شده است که پیش‌بینی جریان ترافیک بیش از پیش اهمیت یابد. پژوهش‌های جدید نشان می‌دهند که خطای پیش‌بینی حتی در حد ۵ تا ۱۰ درصد می‌تواند منجر به افزایش چشمگیر در زمان سفر و مصرف انرژی در شبکه‌های پرتراffic شود. به همین دلیل، در بازه ۲۰۲۳ تا ۲۰۲۵ شاهد رشد چشمگیری در کاربرد مدل‌های هیبریدی و عمیق برای مدیریت هوشمند ترافیک بوده‌ایم. به‌طور خاص، ترکیب روش‌های مبتنی بر یادگیری عمیق مانند LSTM با الگوریتم‌های کلاسیک قدرتمند همچون XGBoost به یکی از روندهای پژوهشی غالب تبدیل شده است. این امر به دلیل توانایی مدل‌های ترکیبی در پوشش همزمان الگوهای مکانی-زمانی و روابط غیرخطی در داده‌ها است.

در سال‌های اخیر، توجه پژوهشگران به استفاده از روش‌های ترکیبی و هوشمند برای ارتقاء دقت پیش‌بینی افزایش یافته است. [۹]، [۱۰]، [۱۱] الگوریتم تقویت گرادیان (XGBoost) به عنوان یکی از روش‌های برجسته یادگیری ماشین، به دلیل دقت بالا، توانایی در پردازش داده‌های بزرگ، و قابلیت تفسیرپذیری، در بسیاری از مطالعات مورد توجه قرار گرفته است. [۲]، [۱۲]، [۱۳] از سوی دیگر، مدل‌های یادگیری عمیق مانند LSTM و CNN^۵ نیز به‌طور گسترده برای استخراج الگوهای زمانی و مکانی از داده‌های ترافیکی مورد استفاده قرار گرفته‌اند. [۱۴] ترکیب این الگوریتم‌ها در قالب مدل‌های هیبرید، گامی مؤثر در جهت بهبود عملکرد سیستم‌های پیش‌بینی ترافیک محسوب می‌شود. [۹]، [۱۵]

در این فصل، ابتدا مفاهیم پایه مرتبط با سیستم‌های حمل‌ونقل هوشمند، یادگیری ماشین و یادگیری عمیق ارائه می‌شود. سپس روش‌های یادگیری مورد استفاده در پیش‌بینی جریان

^۱ Internet Of Vehicles

^۲ Internet Of Things

^۳ Connected Vehicles

^۴ Vehicle-to-Everything

^۵ Convolutional Neural Network

ترافیک به صورت دسته‌بندی شده مورد بررسی قرار می‌گیرند. در ادامه، مطالعات داخلی و خارجی مرتبط با موضوع تحقیق مرور شده و در نهایت با جمع‌بندی نکات کلیدی، شکاف‌های پژوهشی موجود استخراج خواهد شد تا بستر لازم برای ارائه مدل پیشنهادی در فصل بعد فراهم گردد.

۲-۲- مفاهیم پایه

در این بخش، مفاهیم نظری و فناوری‌های کلیدی که مبنای تحقیق حاضر را تشکیل می‌دهند، معرفی و تشریح می‌شوند. این مفاهیم شامل سیستم‌های حمل‌ونقل هوشمند، جریان ترافیک و ویژگی‌های آن، الگوریتم‌های یادگیری ماشین و یادگیری عمیق، و معرفی اولیه الگوریتم XGBoost و مدل‌های ترکیبی مورد استفاده در پیش‌بینی جریان ترافیک است.

۲-۲-۱- سیستم حمل و نقل هوشمند (ITS)

سیستم‌های حمل‌ونقل هوشمند به مجموعه‌ای از فناوری‌ها و زیرساخت‌های اطلاعاتی اطلاق می‌شود که با هدف بهبود کارایی، ایمنی و پایداری حمل‌ونقل، طراحی و پیاده‌سازی می‌شوند. ITS شامل اجزایی مانند سیستم‌های پایش ترافیک، مدیریت بلادرنگ، سامانه‌های ناوبری، ارتباطات بین وسایل نقلیه^۱ (V2V) و ارتباط با زیرساخت‌ها^۲ (V2I) است. یکی از زیرمجموعه‌های اصلی ITS، پیش‌بینی جریان ترافیک است که با تحلیل داده‌های گذشته، وضعیت آتی ترافیک را برآورد می‌کند. [۳]، [۱۸]

سیستم‌های حمل‌ونقل هوشمند تنها به مدیریت ترافیک محدود نمی‌شوند، بلکه طیفی از خدمات نظیر ایمنی جاده‌ای، مدیریت ناوگان حمل‌ونقل عمومی، سامانه‌های پرداخت الکترونیکی، و حتی مدیریت پارکینگ‌های هوشمند را نیز در بر می‌گیرند. در سطح جهانی، سرمایه‌گذاری در ITS به‌طور میانگین سالانه بیش از ۱۰ درصد رشد داشته است و بسیاری از کلان‌شهرها بودجه‌های ویژه‌ای را برای توسعه زیرساخت‌های داده‌محور این سیستم‌ها اختصاص می‌دهند.

۲-۲-۲- جریان ترافیک و پیش‌بینی آن

جریان ترافیک معمولاً به تعداد وسایل نقلیه عبوری از یک مقطع مشخص در واحد زمان گفته می‌شود و با متغیرهایی مانند حجم، سرعت متوسط، چگالی^۳ و نرخ اشغال^۴ توصیف

^۱ Vehicle-to-Vehicle

^۲ Vehicle-to-Infrastructure

^۳ Density

^۴ Occupancy

می‌شود. [۱۶] پیش‌بینی جریان ترافیک یک مسئله دینامیک، غیرخطی و وابسته به زمان و مکان است که به داده‌های حجیم، ناپیوسته و چندمنبعی وابسته است. [۱]، [۱۷] موفقیت در پیش‌بینی جریان ترافیک می‌تواند منجر به اتخاذ تصمیمات مؤثر در مدیریت مسیرها، تخصیص منابع و کاهش ازدحام شود. [۱]، [۵]

علاوه بر شاخص سرعت و حجم، متغیرهای دیگری همچون چگالی، نرخ اشغال و زمان سفر^۱ نیز به عنوان معیارهای کلیدی در تحلیل جریان ترافیک شناخته می‌شوند. مطالعات جدید نشان داده‌اند که استفاده هم‌زمان از این شاخص‌ها می‌تواند دقت پیش‌بینی را تا ۱۵٪ افزایش دهد.

۲-۲-۳- یادگیری ماشین (ML)

یادگیری ماشین شاخه‌ای از هوش مصنوعی است که به سیستم‌ها اجازه می‌دهد از داده‌ها الگو بیاموزند و بدون برنامه‌ریزی صریح، پیش‌بینی یا تصمیم‌گیری کنند. در زمینه پیش‌بینی جریان ترافیک، الگوریتم‌هایی مانند رگرسیون خطی^۲، درخت تصمیم^۳، جنگل تصادفی^۴، SVM^۵ و به ویژه XGBoost از پرکاربردترین روش‌ها به‌شمار می‌روند. این الگوریتم‌ها قابلیت تحلیل ویژگی‌های مؤثر بر ترافیک و مدل‌سازی روابط پیچیده بین متغیرها را دارا هستند. [۲۱]

الگوریتم‌های یادگیری ماشین در ترافیک نه تنها برای پیش‌بینی جریان، بلکه برای تشخیص ناهنجاری‌ها^۶ مانند تصادفات یا انسداد مسیر نیز کاربرد گسترده دارند. همچنین استفاده از الگوریتم‌هایی چون XGBoost و جنگل تصادفی به دلیل قابلیت پردازش داده‌های حجیم و چندبعدی، در پروژه‌های مقیاس کلان شهری به سرعت در حال گسترش است.

۲-۲-۴- یادگیری عمیق (DL)

یادگیری عمیق زیرمجموعه‌ای از یادگیری ماشین است که با بهره‌گیری از شبکه‌های عصبی با لایه‌های پنهان متعدد، توانایی مدل‌سازی روابط بسیار پیچیده، غیرخطی و متغیرهای با ابعاد بالا را دارد. در مسائل ترافیکی، مدل‌هایی مانند LSTM برای تحلیل توالی زمانی، CNN برای استخراج ویژگی‌های مکانی، و مدل‌های ترکیبی (مثل CNN-LSTM یا GRU-Attention) جهت مدل‌سازی هم‌زمان ویژگی‌های زمانی و مکانی کاربرد فراوان دارند. [۱۴]، [۱۸]

یادگیری عمیق امکان مدل‌سازی ساختارهای پیچیده مکانی-زمانی را فراهم کرده است.

^۱ Travel Time

^۲ Linear Regression

^۳ Decision Tree

^۴ Random Forest

^۵ Support Vector Machine

^۶ Anomaly Detection

معماری‌هایی نظیر Attention Mechanism، GCN^۱ و Transformers در سال‌های اخیر برای تحلیل داده‌های ترافیکی مورد استفاده قرار گرفته‌اند. این روش‌ها به‌ویژه در داده‌های حاصل از سنسورها و GPS، عملکرد بهتری نسبت به مدل‌های سنتی نشان داده‌اند.

۵-۲-۲- الگوریتم XGBoost و مدل‌های ترکیبی

الگوریتم XGBoost (Extreme Gradient Boosting) یکی از قدرتمندترین الگوریتم‌های تقویت‌گرادیان است که بر پایه درخت‌های تصمیم کار می‌کند. این الگوریتم به واسطه عملکرد سریع، توانایی مقابله با داده‌های گمشده، جلوگیری از بیش‌برازش^۲ و تفسیرپذیری بالا، به طور گسترده در پروژه‌های داده‌محور از جمله پیش‌بینی ترافیک به‌کار گرفته می‌شود.^[۵] ترکیب XGBoost با مدل‌های یادگیری عمیق مانند LSTM یا CNN، به‌عنوان یک راهکار موثر برای بهره‌گیری هم‌زمان از قدرت استخراج ویژگی و دقت پیش‌بینی شناخته شده است.^[۹]

XGBoost یکی از پیشرفته‌ترین پیاده‌سازی‌های الگوریتم Gradient Boosting به‌شمار می‌رود که با بکارگیری تکنیک‌هایی مانند هرس درخت‌ها^۳، منظم‌سازی^۴ و مدیریت داده‌های گمشده به مدلی پایدار، دقیق و کارآمد در کاربردهای واقعی تبدیل شده است. مطالعات اخیر نشان می‌دهند که XGBoost در مقایسه با سایر روش‌های تجمعی^۶ نه تنها از سرعت آموزش بالاتری برخوردار است، بلکه توانایی تعمیم‌پذیری بیشتری نیز ارائه می‌دهد.

۳-۲- روش‌های یادگیری مورد استفاده در پیش‌بینی جریان ترافیک

پیش‌بینی جریان ترافیک به عنوان یکی از مسائل حیاتی در حوزه حمل‌ونقل هوشمند، در سال‌های اخیر با بهره‌گیری از تکنیک‌های پیشرفته یادگیری ماشین و یادگیری عمیق بهبود قابل توجهی یافته است. از آن‌جا که داده‌های ترافیکی معمولاً شامل روابط پیچیده، غیرخطی و وابسته به زمان و مکان هستند، استفاده از الگوریتم‌های یادگیری داده‌محور^۷ می‌تواند به شناسایی الگوهای پنهان در داده‌ها و افزایش دقت پیش‌بینی کمک کند.^[۱] در این بخش، پرکاربردترین روش‌های مورد استفاده در ادبیات موجود به صورت دسته‌بندی‌شده معرفی می‌شوند.

^۱ Graph Convolutional Networks

^۲ overfitting

^۳ Pruning

^۴ L_1/L_2 Regularization

^۵ Handling Missing Values

^۶ Ensemble Methods

^۷ Data-driven Learning Algorithms

۱-۳-۲- مدل‌های آماری سنتی

مدل‌های آماری پایه مانند $ARIMA$ ^۱، $SARIMA$ ^۲ و فیلتر کالمن^۳ از نخستین رویکردهای مورد استفاده در پیش‌بینی ترافیک محسوب می‌شوند. [۱۹] این مدل‌ها فرض می‌کنند که ساختار داده‌ها از نوع سری زمانی خطی و ایستا است و به همین دلیل، در پیش‌بینی کوتاه‌مدت در شرایط با نوسان کم عملکرد قابل قبولی دارند. با این حال، در مواجهه با داده‌های غیرخطی، نویزی و پویا، دقت آن‌ها کاهش می‌یابد.

علی‌رغم محدودیت‌های شناخته‌شده، مدل‌های آماری همچنان در برخی کاربردهای عملی به‌کار می‌روند. برای مثال، مدل $ARIMAX$ ^۴ با افزودن متغیرهای برون‌زا مانند شرایط آب‌وهوایی می‌تواند دقت پیش‌بینی را بهبود دهد. همچنین ترکیب فیلتر کالمن با مدل‌های تطبیقی، در داده‌های نویزی و کوتاه‌مدت هنوز هم نتایج قابل قبولی ارائه می‌دهد. با این حال، مشکل اصلی این روش‌ها، فرض ایستایی داده‌ها و ناتوانی در مدل‌سازی روابط غیرخطی است.

۲-۳-۲- روش‌های یادگیری ماشین (ML)

الگوریتم‌های یادگیری ماشین به دلیل قابلیت مدل‌سازی روابط غیرخطی و یادگیری از داده‌های متنوع، به طور گسترده در پیش‌بینی جریان ترافیک به‌کار رفته‌اند. [۲۰] از جمله رایج‌ترین روش‌ها می‌توان به موارد زیر اشاره کرد:

- درخت تصمیم و جنگل تصادفی:
مدل‌هایی قابل تفسیر با توانایی بالا در تحلیل ویژگی‌ها و مقابله با داده‌های نویزی.

- ماشین بردار پشتیبان (SVM):
مناسب برای مسائل دسته‌بندی یا رگرسیون با حجم داده نسبتاً کم.

- XGBoost:
الگوریتم تقویت‌گرایدی که به دلیل دقت بالا، سرعت آموزش سریع و قابلیت مقابله با بیش‌برازش، به طور گسترده در پروژه‌های بزرگ مقیاس مورد استفاده قرار گرفته است.

الگوریتم‌های جدید مانند LightGBM و CatBoost نیز در کنار XGBoost مورد توجه پژوهشگران قرار گرفته‌اند. این روش‌ها با استفاده از درخت‌های گرادیان تقویت‌شده، امکان پردازش سریع‌تر داده‌های بزرگ را فراهم کرده و نسبت به داده‌های نامتوازن حساسیت

^۱ AutoRegressive Integrated Moving Average

^۲ Seasonal AutoRegressive Integrated Moving Average

^۳ Kalman filter

^۴ AutoRegressive Integrated Moving Average with Exogenous

کمتری دارند. همچنین استفاده از روش‌های انتخاب ویژگی (Feature Selection) در ترکیب با ML موجب کاهش ابعاد و بهبود سرعت آموزش شده است.

۳-۳-۲- روش‌های یادگیری عمیق (DL)

یادگیری عمیق با تکیه بر شبکه‌های عصبی چندلایه، توانایی استخراج الگوهای پیچیده زمانی و مکانی از داده‌های ترافیکی را فراهم می‌سازد. [۲۱] مهم‌ترین مدل‌ها در این زمینه عبارتند از:

- LSTM (Long Short-Term Memory): مناسب برای داده‌های ترتیبی و دارای حافظه بلندمدت، توانمند در مدل‌سازی روابط زمانی.
- GRU (Gated Recurrent Unit): نسخه ساده‌تر و سریع‌تر از LSTM با دقت قابل مقایسه.
- CNN (Convolutional Neural Network): بیشتر برای استخراج ویژگی‌های مکانی یا تحلیل تصاویر ترافیکی به‌کار می‌رود.
- SAE (Stacked Autoencoder)، DBN (Deep Belief Network)، و سایر معماری‌های عمیق مورد استفاده برای فشرده‌سازی، کاهش ابعاد یا بازسازی داده‌های گمشده.

مدل‌های جدید مبتنی بر Attention Mechanism و Transformers توانسته‌اند وابستگی‌های بلندمدت را بهتر از LSTM مدل کنند. همچنین Graph Neural Networks (GNNs) و به‌ویژه Spatio-Temporal GCN (ST-GCN) در سال‌های اخیر به‌طور گسترده برای پیش‌بینی جریان ترافیک شبکه‌ای استفاده شده‌اند. این مدل‌ها روابط مکانی بین گره‌های جاده‌ای را بهتر از CNN سنتی درک می‌کنند.

۴-۳-۲- مدل‌های ترکیبی و ساختارهای پیشرفته

به‌منظور بهره‌برداری هم‌زمان از توانمندی‌های الگوریتم‌های مختلف، بسیاری از پژوهش‌ها به ترکیب مدل‌ها پرداخته‌اند. مدل‌های ترکیبی طیف گسترده‌ای از معماری‌ها را شامل می‌شوند. برای نمونه:

- LSTM-XGBoost: استخراج ویژگی‌های زمانی توسط LSTM و پیش‌بینی نهایی با XGBoost
- CNN-LSTM: تحلیل مکانی با CNN و مدل‌سازی زمانی با LSTM
- Wavelet-XGBoost: حذف نویز از طریق تبدیل موجک و پیش‌بینی با XGBoost
- GCN-LSTM یا ST-GCN: استفاده از گراف برای مدل‌سازی ساختار جاده و LSTM برای زمان‌بندی
- Wavelet-XGBoost: حذف نویز داده‌ها با تبدیل موجک و سپس پیش‌بینی.
- CNN-LSTM: تحلیل مکانی توسط CNN و تحلیل زمانی توسط LSTM.

- GCN-LSTM: ترکیب گراف و وابستگی زمانی.
- Attention-LSTM-XGBoost: استفاده از مکانیسم توجه برای بهبود استخراج ویژگی‌ها و سپس تقویت پیش‌بینی با XGBoost.

این مدل‌های ترکیبی، معمولاً عملکرد بهتری نسبت به مدل‌های مستقل دارند، به‌ویژه در شرایطی که داده‌ها دارای ویژگی‌های چندمنبعی، ناقص یا پیچیده هستند. مدل‌های ترکیبی به‌عنوان نسل جدیدی از رویکردهای پیش‌بینی شناخته می‌شوند. این مدل‌ها با ادغام نقاط قوت الگوریتم‌های مختلف، ضعف‌های آن‌ها را پوشش می‌دهند. برای مثال، ترکیب LSTM (مناسب برای وابستگی‌های زمانی) با CNN (مناسب برای استخراج ویژگی‌های مکانی) و XGBoost (مناسب برای پردازش غیرخطی) یکی از ساختارهایی است که در مقالات اخیر نتایج بسیار دقیقی ارائه داده است.

جدول (۲-۱) مقایسه رویکردهای ترکیبی در پیش‌بینی جریان ترافیک

کاربرد نمونه	محدودیت‌ها	مزایا	رویکرد
پیش‌بینی جریان ترافیک در سری‌های زمانی پیوسته	نیاز به تنظیم دقیق هاپرپارامترها؛ افزایش پیچیدگی محاسباتی	ترکیب قدرت LSTM در مدل‌سازی وابستگی‌های زمانی و دقت بالای XGBoost در پیش‌بینی غیرخطی؛ مقاومت در برابر داده‌های گم‌شده	LSTM-XGBoost
تحلیل جریان ترافیک در شبکه‌های جاده‌ای با چندین سنسور	نیازمند داده‌های با ابعاد مکانی دقیق؛ هزینه محاسباتی بالا	استخراج ویژگی‌های مکانی توسط CNN و ویژگی‌های زمانی توسط LSTM؛ مناسب داده‌های مکانی-زمانی	CNN-LSTM
پیش‌بینی سرعت یا حجم ترافیک در داده‌های نویزی و ناپایدار	انتخاب مناسب مقیاس موجک چالش‌برانگیز است؛ امکان از دست رفتن بخشی از اطلاعات	حذف نویز داده‌ها با تبدیل موجک و بهبود دقت پیش‌بینی؛ کارایی بالا در داده‌های ناپایدار	Wavelet-XGBoost
مدل‌سازی ترافیک در شبکه‌های بزرگراهی و سیستم‌های هوشمند شهری	نیازمند داده‌های گراف دقیق از شبکه جاده‌ای؛ پیچیدگی بالای پیاده‌سازی	مدل‌سازی وابستگی‌های ساختاری شبکه جاده‌ای با گراف و وابستگی‌های زمانی با LSTM؛ مناسب داده‌های سنسوری مکانی-زمانی	GCN-LSTM / ST-GCN
پیش‌بینی بلادرنگ در سیستم‌های ITS و مدیریت ترافیک پیشگیرانه	افزایش چشمگیر پیچیدگی مدل؛ نیاز به منابع محاسباتی بالا	استفاده از مکانیزم توجه برای استخراج ویژگی‌های مهم؛ ترکیب با XGBoost برای پیش‌بینی قوی‌تر	Attention-LSTM-XGBoost

۲-۴- مطالعات داخلی

در سال‌های اخیر، پژوهشگران ایرانی نیز به‌دلیل رشد سریع شهرنشینی و افزایش نیاز به مدیریت هوشمند حمل‌ونقل، به استفاده از روش‌های یادگیری ماشین و یادگیری عمیق در حوزه پیش‌بینی جریان ترافیک روی آورده‌اند. با وجود محدودیت دسترسی به داده‌های باز در کشور، برخی مطالعات توانسته‌اند با بهره‌گیری از داده‌های جمع‌آوری‌شده از سامانه‌های ترافیکی داخلی یا شبیه‌سازها، نتایج قابل قبولی ارائه دهند. در ادامه، برخی از مهم‌ترین مطالعات داخلی مرور می‌شوند.

زمانی و میرزاحسین (۱۴۰۰) در پژوهشی با عنوان «مروری بر کاربرد انواع مدل‌های مبتنی بر یادگیری عمیق در پیش‌بینی پارامترهای جریان ترافیک»، که در فصلنامه «مطالعات مدیریت ترافیک» منتشر شده به تحلیل و طبقه‌بندی مطالعات داخلی و خارجی انجام‌شده در حوزه پیش‌بینی ترافیک با استفاده از مدل‌های یادگیری عمیق پرداخته‌اند. در این مقاله، مجموعاً ۵ مقاله داخلی و ۴۵ مقاله خارجی (از پایگاه‌هایی نظیر IEEE و ScienceDirect) تحلیل شده‌اند.

نویسندگان مدل‌های یادگیری عمیق را به دو دسته کلی تقسیم می‌کنند:

- مدل‌های تک‌لایه مانند LSTM، GRU و CNN
- مدل‌های ترکیبی مانند CNN-LSTM، Hybrid SAE-DBN و GCN-LSTM
- نتایج این مرور نشان می‌دهد که:
- مدل‌های ترکیبی یادگیری عمیق، عملکرد بهتری در پیش‌بینی متغیرهایی نظیر سرعت، حجم و تراکم ترافیک داشته‌اند.
- در اغلب مطالعات، استفاده از داده‌های مکانی-زمانی چندمنبعی، دقت پیش‌بینی را افزایش داده است.
- همچنین استفاده از روش‌های همجوشی ویژگی‌ها و لایه‌های چندگانه، مقاومت مدل‌ها در برابر داده‌های نویزی را بهبود بخشیده است.

در انتهای مقاله، نویسندگان پیشنهاد می‌کنند که پژوهش‌های آینده تمرکز بیشتری بر ترکیب الگوریتم‌های یادگیری عمیق با روش‌های بهینه‌سازی، انتخاب ویژگی، و الگوریتم‌های سبک‌تر مانند XGBoost داشته باشند. [۲۵]

بهادری و موسوی (۱۴۰۰) در مقاله‌ای با عنوان «پیش‌بینی کوتاه‌مدت سرعت جریان ترافیک با استفاده از مدل‌های سری‌های زمانی»، ارائه‌شده در اولین کنفرانس ملی مهندسی عمران، توسعه هوشمند و سیستم‌های پایدار به بررسی قابلیت مدل‌های سری زمانی در پیش‌بینی سرعت جریان ترافیک پرداختند. در این مطالعه، داده‌های مربوط به سرعت جریان ترافیک جمع‌آوری‌شده در سال ۱۳۹۳ مورد استفاده قرار گرفت. هدف اصلی، پیش‌بینی سرعت جریان ترافیک برای یک ساعت آینده با استفاده از مدل‌های سری زمانی بود. نتایج به‌دست‌آمده نشان داد که مدل پیشنهادی توانست برای معیارهای ارزیابی میانگین خطای مطلق (MAE)، مجذور میانگین مربعات خطا (RMSE) و میانگین درصد خطای مطلق (MAPE)، به‌ترتیب مقادیر ۳/۷۴۵، ۲/۶۴۱ و ۳/۱۶۲ را به‌دست آورد.

این پژوهش نشان می‌دهد که مدل‌های سری زمانی می‌توانند ابزار مؤثری در پیش‌بینی کوتاه‌مدت سرعت جریان ترافیک باشند، هرچند که در مواجهه با داده‌های نویزی و شرایط پیچیده‌تر، ممکن است نیاز به ترکیب با سایر روش‌های پیشرفته‌تر وجود داشته باشد. رجبی و مقدسی (۱۴۰۳) در مقاله‌ای با عنوان «مروری بر روش‌های نوین پیش‌بینی هوشمند جریان ترافیک»، ارائه‌شده در چهارمین کنفرانس ملی مهندسی عمران، توسعه هوشمند و سیستم‌های پایدار به بررسی نقش پیش‌بینی جریان ترافیک در بهبود عملکرد سیستم‌های حمل‌ونقل هوشمند (ITS) پرداخته‌اند. آن‌ها ضمن معرفی برنامه‌های کاربردی ITS، به تحلیل اثرات مثبت پیش‌بینی ترافیک بر عملکرد این برنامه‌ها پرداخته و روش‌های مختلف پیش‌بینی، از جمله روش‌های آماری و مبتنی بر یادگیری ماشین، را معرفی کرده‌اند.

در این مطالعه، تأکید شده است که روش‌های آماری به دلیل ساختار مدل دقیق، محدودیت‌هایی در سازگاری دارند، در حالی که مدل‌های یادگیری ماشین از انعطاف‌پذیری بیشتری برخوردارند. نویسندگان با معرفی ویژگی‌های روش‌های پیش‌بینی هوشمند جریان ترافیک، تلاش کرده‌اند تا گامی در جهت راهگشایی تحقیقات آینده بردارند. [۲۶]

رسائی‌زادی و سیدابریشمی (۱۴۰۱) در پژوهشی منتشرشده در نشریه مهندسی عمران

امیرکبیر به پیش‌بینی وضعیت ترافیک (روان، نیمه‌سنگین و سنگین) در محور برون‌شهری کرج-چالوس پرداخته‌اند. در این مطالعه سه رویکرد SVM، Random Forest و LSTM برای افق‌های زمانی کوتاه‌مدت و میان‌مدت مورد بررسی قرار گرفته است. نتایج نشان می‌دهد که مدل LSTM عملکرد دقیق‌تری نسبت به دو مدل دیگر داشته و در افق کوتاه‌مدت به دقتی حدود ۹۰٪ و در افق میان‌مدت به حدود ۸۲٪ دست یافته است. همچنین بالاترین مقدار شاخص F۱ برای هر سه کلاس ترافیکی توسط این مدل گزارش شده است. [۲۷]

توکلی و همکاران (۲۰۲۳/۱۴۰۲) در مقاله‌ای ب ه مسئله پیش‌بینی کوتاه‌مدت سرعت ترافیک با استفاده از شبکه‌های عصبی پرداخته‌اند. در این پژوهش، عملکرد مدل‌های یادگیری عمیق در مقایسه با روش‌های سنتی مورد ارزیابی قرار گرفته و نشان داده شده است که شبکه‌های عصبی در پیش‌بینی متغیرهای ترافیکی مانند سرعت و جریان از دقت بالاتری برخوردارند. همچنین نویسندگان بر اهمیت ملاحظات مربوط به داده‌های واقعی در پیاده‌سازی مدل‌ها تأکید کرده‌اند. [۲۸]

در یک مقاله کنفرانسی منتشرشده در سال ۲۰۲۴/۱۴۰۲ در پایگاه Civilica، به پیش‌بینی کوتاه‌مدت سرعت ترافیک با استفاده از الگوریتم LSTM پرداخته شده است. در این پژوهش، چندین مدل یادگیری عمیق در افق‌های زمانی مختلف با یکدیگر مقایسه شده‌اند. نتایج نشان می‌دهد که مدل LSTM در بیشتر بازه‌های زمانی عملکرد بهتری نسبت به مدل‌های پایه داشته و دقت پیش‌بینی قابل‌توجهی را ارائه کرده است. [۲۸]

در یک پژوهش منتشرشده در سال ۲۰۲۲/۱۴۰۰ در پایگاه Civilica، مسئله پیش‌بینی زمان سفر بر اساس داده‌های ترافیکی به‌دست‌آمده از شناساگرها بررسی شده است. در این تحقیق، چندین پیکربندی مختلف از مدل LSTM و نسخه‌های ترکیبی آن طراحی و مورد استفاده قرار گرفته است. ارزیابی‌ها بر روی داده‌های واقعی و در افق‌های زمانی گوناگون انجام شده و نشان داده‌اند که مدل‌های مبتنی بر LSTM توانسته‌اند دقت بالاتری نسبت به رویکردهای پایه در پیش‌بینی زمان سفر ارائه دهند. [۲۹]

جدول (۲-۲) مقایسه مقالات منتخب داخلی

پیشنهادهای/نتایج کلیدی	نتایج	داده‌ها	مدل‌های بررسی شده	مقاله
پیشنهاد به ترکیب یادگیری عمیق با روش‌های بهینه‌سازی و الگوریتم‌های سبک‌تر مانند XGBoost	مدل‌های ترکیبی دقت بالاتری در پیش‌بینی دارند. استفاده از داده‌های مکانی-زمانی چندمنبعی دقت را افزایش داده است.	داده‌های ترافیکی داخلی و خارجی	مدل‌های تک‌لایه (LSTM، GRU)، مدل‌های ترکیبی (CNN، LSTM Hybrid، GCN-، SAE-DBN (LSTM)	زمانی و میرزاحسین (۱۴۰۰)
پیشنهاد ترکیب مدل‌های سری زمانی با روش‌های پیشرفته‌تر برای بهبود دقت در شرایط پیچیده	مدل پیشنهادی در پیش‌بینی سرعت جریان ترافیک برای یک ساعت آینده عملکرد خوبی داشت (MAE: ۲/۶۴۱)	داده‌های سرعت جریان ترافیک در سال ۱۳۹۳	مدل‌های سری زمانی	بهادری و موسوی (۱۴۰۰)
پیشنهاد استفاده بیشتر از مدل‌های یادگیری ماشین برای پیش‌بینی جریان ترافیک	مدل‌های یادگیری ماشین نسبت به روش‌های آماری دقت بالاتری دارند.	داده‌های ترافیکی شهری	روش‌های آماری و یادگیری ماشین	رجبی و مقدسی (۱۴۰۳)
پیشنهاد استفاده از LSTM برای پیش‌بینی وضعیت ترافیک در افق‌های زمانی مختلف	مدل LSTM بهترین عملکرد را داشت (دقت ۹۰٪ در افق کوتاه‌مدت).	داده‌های ترافیکی محور کرج-چالوس	SVM، Random LSTM، Forest	رسائی‌زادی و سیدابریشمی (۱۴۰۱)
تأکید بر اهمیت داده‌های واقعی در پیاده‌سازی مدل‌های پیش‌بینی ترافیک	شبکه‌های عصبی دقت بالاتری در پیش‌بینی متغیرهای ترافیکی داشتند.	داده‌های سرعت ترافیک	شبکه‌های عصبی	توکلی و همکاران (۲۰۲۳/۱۴۰۲)
تأکید بر استفاده از LSTM در پیش‌بینی‌های کوتاه‌مدت و مقایسه آن با مدل‌های پایه	مدل LSTM عملکرد بهتری نسبت به مدل‌های پایه داشت و دقت پیش‌بینی قابل‌توجهی را ارائه داد.	داده‌های ترافیکی مختلف	LSTM	مقاله Civilica (۲۰۲۴/۱۴۰۲)
پیشنهاد استفاده از مدل‌های LSTM برای پیش‌بینی زمان سفر در افق‌های زمانی مختلف	مدل‌های مبتنی بر LSTM دقت بالاتری در پیش‌بینی زمان سفر نسبت به رویکردهای پایه داشتند.	داده‌های شناساگرها	LSTM و نسخه‌های ترکیبی آن	مقاله Civilica (۲۰۲۲/۱۴۰۰)

۲-۵. مطالعات خارجی

برای بررسی دقیق‌تر رویکردهای موجود در پیش‌بینی جریان ترافیک، مقالات معتبر بین‌المللی به چهار گروه اصلی طبقه‌بندی شده‌اند: مدل‌های مبتنی بر XGBoost، مدل‌های یادگیری عمیق، مدل‌های ترکیبی و مطالعات مبتنی بر داده‌های چندمنبعی یا تقویت‌شده. در ادامه، نمونه‌هایی از این مطالعات مرور و تحلیل می‌شوند

الف) مطالعات مبتنی بر XGBoost

۱. مقاله: "Short-Term Traffic Flow Prediction Based on XGBoost" (۲۰۲۲)
در این پژوهش، از الگوریتم XGBoost به همراه پردازش موجک (Wavelet Transform) برای حذف نویز و بهبود دقت پیش‌بینی استفاده شده است. داده‌ها شامل حجم ترافیک و سرعت در محورهای پرتردد شهری بوده و نتایج با معیارهایی مانند MAE و RMSE ارزیابی شده‌اند. دقت مدل نسبت به روش‌های SVM و Random Forest به‌طور محسوسی بالاتر بوده است. [۱۵]
۲. مقاله: "Prediction of High-Speed Traffic Flow Based on BO-XGBoost" (۲۰۲۳):
این مطالعه از الگوریتم XGBoost بهینه‌سازی‌شده با بهینه‌سازی بیزی استفاده کرده است. تمرکز بر داده‌های آزادراهی در بازه‌های ماهانه بوده و نتایج نشان می‌دهد BO-XGBoost می‌تواند با MAPE کمتر از ۳٪، عملکرد بالایی در سناریوهای واقعی از خود نشان دهد. [۲۲]

ب) مطالعات مبتنی بر یادگیری عمیق (LSTM، CNN، GRU و...)

۳. مقاله: "T-LSTM: A Long Short-Term Memory Enhanced by Temporal Information" (۲۰۱۹)
در این مقاله، از نسخه بهبودیافته LSTM با ورودی‌های زمانی صریح (مثل روز هفته، ساعت) استفاده شده است. همچنین از مکانیزم بازسازی داده‌های گمشده بهره گرفته شده که دقت مدل را در شرایط ناقص افزایش داده است. [۲۳]
۴. مقاله: "Polson & Deep Learning for Short-Term Traffic Flow Prediction" (۲۰۱۷ Sokolov,
یکی از مطالعات شاخص که ترکیب LSTM و مدل‌های regularized linear را برای پیش‌بینی جریان بزرگراهی با داده‌های واقعی ایالت ایلینوی آمریکا ارائه داده است. مقاله عملکرد مدل را با استفاده از dropout و regularization تثبیت می‌کند. [۲۴]

پ) مطالعات مبتنی بر مدل‌های ترکیبی

۵. مقاله: "Short-Term Traffic Flow Prediction Based on LSTM-XGBoost Combination Model" (۲۰۲۳)
مدلی ترکیبی که ابتدا ویژگی‌های زمانی را با LSTM استخراج کرده و سپس XGBoost برای پیش‌بینی نهایی استفاده شده. نتایج نشان داد که این ترکیب نسبت به

LSTM تنها یا XGBoost تنها، عملکرد پایدارتری دارد و دقت را تا ۱۰٪ افزایش داده است. [۲۵]

۶. مقاله: "Spatio-Temporal Segmented Traffic Flow Prediction with ANPRS Data Based on Improved XGBoost" (۲۰۲۲)
در این مقاله، داده‌های پلاک‌خوانی (ANPRS) به‌صورت بخش‌بندی‌شده تحلیل شده و مدل XGBoost تقویت‌شده با داده‌های تأخیردار مکانی-زمانی استفاده شده است. ترکیب ورودی با تأخیر و تنظیمات Local باعث افزایش دقت در شرایط پرتراфик شده است. [۲۶]

ت) مطالعات مبتنی بر داده‌های چندمنبعی و ویژگی‌های مکمل
۷. مقاله: "Traffic Flow Prediction with Rainfall Impact Using Deep Learning" (۲۰۲۱)
داده‌های آب‌وهوایی (بارندگی) به‌عنوان ورودی به مدل LSTM اضافه شده و نتایج نشان داده که افزودن متغیرهای محیطی دقت مدل را به‌طور قابل توجهی افزایش داده است. این مقاله کاربردی مهم برای توسعه مدل چندمنبعی محسوب می‌شود. [۲۷]
۸. مقاله: "Traffic Speed Prediction Based on Deep Feature Fusion" (۲۰۲۲)
ترکیب Autoencoder و SVR برای پیش‌پردازش داده‌های چندمنبعی (ویدئو، GPS، حسگر جاده‌ای) مورد استفاده قرار گرفته. خروجی مدل نسبت به روش‌های سنتی دقیق‌تر و پایدارتر بوده است. [۲۸]

ث) مقالات دسته بندی نشده
در پژوهشی مربوط به سال ۲۰۲۵ مدلی ترکیبی مبتنی بر LSTM و XGBoost برای پیش‌بینی جریان ترافیک شهری ارائه شد. داده‌های مورد استفاده شامل سرعت وسایل نقلیه و موقعیت‌های GPS در یکی از شهرهای آفریقا بودند. در مدل پیشنهادی، ابتدا LSTM برای استخراج وابستگی‌های زمانی داده‌ها به‌کار گرفته شد و سپس خروجی آن به XGBoost داده شد تا پیش‌بینی نهایی انجام گیرد. نتایج نشان داد مدل ترکیبی توانست نسبت به LSTM و XGBoost منفرد، حدود ۹ تا ۱۲ درصد خطا را کاهش دهد. همچنین عملکرد مدل در شرایط پرتراфик و داده‌های نویزی نیز پایدار باقی ماند. اهمیت این پژوهش در نشان‌دادن قابلیت رویکردهای هیبریدی برای داده‌های چندمنبعی و شرایط واقعی شهری است. [۹]

در پژوهشی [۲۹] نویسندگان مدلی نوین مبتنی بر ترانسفورمرهای مکانی-زمانی معرفی کردند که هدف آن بهبود پیش‌بینی جریان ترافیک در شبکه‌های جاده‌ای پیچیده است. این مدل که ASTTN نام دارد، تلاش می‌کند وابستگی‌های مکانی میان گره‌های شبکه جاده‌ای و همچنین وابستگی‌های زمانی پویا در داده‌های ترافیکی را به‌طور هم‌زمان مدل‌سازی کند. نوآوری اصلی در این پژوهش استفاده از مکانیزم Adaptive Graph Learning است که ساختار گراف جاده‌ای را به‌صورت پویا و متناسب با شرایط ترافیکی به‌روزرسانی می‌کند و بدین ترتیب محدودیت گراف‌های ایستا در مدل‌های پیشین را برطرف می‌سازد.
برای ارزیابی عملکرد، مدل ASTTN بر روی دو دیتاست معتبر METR-LA و PEMS-BAY آزمایش شد و نتایج آن با مدل‌های مرجع مانند DCRNN و ST-GCN مقایسه گردید. یافته‌ها نشان داد که ASTTN توانست در معیارهای مختلف از جمله MAE و RMSE عملکرد بهتری ارائه دهد و به‌ویژه در پیش‌بینی بازه‌های زمانی بلندمدت پایدارتری

نسبت به روش‌های پیشین داشته باشد. اهمیت این پژوهش در نشان‌دادن کارایی رویکردهای مبتنی بر ترانسفورمر و یادگیری گراف تطبیقی برای داده‌های پیچیده ترافیکی است که می‌تواند مسیر تحقیقات آینده را در ترکیب‌سازی مدل‌های Attention-based با ساختارهای مکانی-زمانی هموار سازد.

در مطالعه‌ای در سال (۲۰۲۱) [۳۰]، پژوهشگران رویکردی نوین برای پیش‌بینی جریان ترافیک ارائه دادند که در آن علاوه بر وابستگی‌های مکانی و زمانی، متغیرهای جانبی و محیطی نیز وارد مدل شدند. این متغیرها شامل شرایط آب‌وهوایی (مانند دما و بارش)، اطلاعات مکانی (Points of Interest) و سایر داده‌های زمینه‌ای بودند که در قالب بردار ویژگی به گره‌های گراف اضافه شدند. بدین ترتیب مدل قادر شد تأثیر عوامل خارجی بر الگوهای ترافیکی را بهتر درک کند. نتایج آزمایش روی دیتاست‌های بزرگ نشان داد که AST-GCN در معیارهایی نظیر MAE و RMSE نسبت به مدل‌های مرجع مانند ST-GCN و DCRNN عملکرد بهتری داشت. اهمیت این پژوهش در نشان‌دادن نقش حیاتی داده‌های جانبی در بهبود دقت پیش‌بینی جریان ترافیک به‌ویژه در سناریوهای پیچیده و تحت شرایط محیطی متغیر است.

در پژوهش Lu و همکاران [۲۲] (۲۰۲۳)، مدلی با نام BO-XGBoost ارائه شد که در آن برای پیش‌بینی جریان ترافیک در اتوبان‌های شهری (در اطراف یک شهر در چین) از مکانیزم Bayesian Optimization در کنار XGBoost استفاده شده است. ویژگی کلیدی این رویکرد، خودکارسازی تنظیم پارامترهای حساس مدل مانند عمق درخت، تعداد درخت‌ها و نرخ یادگیری بود. نتایج بررسی‌شده نشان داد مدل BO-XGBoost توانست خطای MAPE حدود ۲.۸۸٪ برای جریان ترافیک و ۳.۱۲٪ برای PCU را به‌دست آورد، که به‌وضوح عملکرد برتر و دقت بالاتری نسبت به مدل‌های پایه XGBoost یا سایر روش‌های یادگیری ماشینی ارائه می‌دهد. اهمیت این مطالعه در نشان‌دادن تأثیر بهینه‌سازی پارامترها در افزایش دقت پیش‌بینی حرکت ترافیک به‌ویژه در شرایط واقعی شهری است.

در مطالعه‌ای دیگر [۳۱] در سال (۲۰۲۳)، پژوهشگران مدلی عمیق بر پایه BiLSTM چندمنظوره با افق‌های زمانی متنوع ارائه دادند که قابلیت ادغام مؤثر اطلاعات کمکی چندگانه نظیر شرایط آب‌وهوایی و زمان را دارد. این مدل با طراحی استراتژی چندافقی، وابستگی‌های کوتاه‌مدت (مثلاً روزانه) و بلندمدت (مثلاً هفتگی) را به‌صورت هم‌زمان بررسی کرده و با استفاده از مکانیزم توجه نرم (soft attention)، وزن‌دهی به تأثیرات مختلف این افق‌های زمانی را به‌صورت پویا انجام می‌دهد. آزمایش‌های جامع روی مجموعه داده‌های Hangst و METR-LA نشان داد که MMLSTM در مقایسه با روش‌های مرجع در وظایف پیش‌بینی ترافیک عملکرد بهتری دارد. اهمیت این مطالعه در توانایی آن در درک تأثیر اطلاعات جانبی و استفاده از ساختار چندافقی با تعبیرپذیری بالا برای کاربردهای واقعی در مدیریت ترافیک است.

جدول (۲-۳) مقایسه مقالات منتخب خارجی

پیشنهادهات/نتایج کلیدی	نتایج	داده‌ها	مدل‌های استفاده‌شده	مقاله
استفاده از پردازش موجک برای حذف نویز و بهبود دقت پیش‌بینی	دقت مدل بالاتر از SVM و Random Forest بود (MAE و RMSE بهبود یافت).	داده‌های ترافیکی شهری	XGBoost + Wavelet Transform	Short-Term Traffic Flow Prediction Based on "XGBoost" (۲۰۲۲)
بهینه‌سازی بیزی برای بهبود دقت مدل در پیش‌بینی جریان ترافیک	MAPE کمتر از ۳٪ در سناریوهای واقعی، عملکرد بالای BO-XGBoost	داده‌های آزادراهی	BO-XGBoost (Bayesian Optimization)	Prediction of High-Speed Traffic Flow Based on "BO-XGBoost" (۲۰۲۳)
استفاده از ورودی‌های زمانی و بازسازی داده‌های گمشده برای افزایش دقت	مدل بهبود یافته LSTM دقت بالاتری در پیش‌بینی داشت.	داده‌های ترافیکی با ورودی‌های زمانی (روز هفته، ساعت)	LSTM + ورودی‌های زمانی صریح	T-LSTM: A Long Short-Term Memory Enhanced by Temporal Information" (۲۰۱۹)
استفاده از dropout و regularization برای تثبیت عملکرد مدل	مدل ترکیب LSTM و regularized linear عملکرد مطلوبی داشت.	داده‌های بزرگراه ایالت ایلینوی آمریکا	LSTM + مدل‌های regularized linear	Deep Learning for "Short-Term Traffic Flow Prediction" Polson & Sokolov, ۲۰۱۷
پیشنهاد ترکیب ویژگی‌های زمانی با LSTM و پیش‌بینی نهایی با XGBoost	ترکیب LSTM و XGBoost عملکرد پایدارتری داشت و دقت را تا ۱۰٪ افزایش داد.	داده‌های ترافیکی شهری	LSTM + XGBoost	Short-Term Traffic Flow Prediction Based on "LSTM-XGBoost Combination Model" (۲۰۲۳)
تقویت XGBoost با داده‌های مکانی-زمانی برای بهبود دقت پیش‌بینی	ترکیب ورودی با تأخیر و تنظیمات Local دقت را در شرایط پرتراffic افزایش داد.	داده‌های پلاک‌خوانی ANPRS	XGBoost + داده‌های ANPRS	Spatio-Temporal "Segmented Traffic Flow Prediction with ANPRS Data Based on Improved" XGBoost" (۲۰۲۲)
استفاده از داده‌های محیطی در مدل‌های پیش‌بینی چندمنبعی	افزودن متغیرهای محیطی (بارندگی) دقت مدل را به‌طور قابل‌توجهی افزایش داد.	داده‌های ترافیکی و آب‌وهوایی	LSTM + داده‌های آب‌وهوایی (بارندگی)	Traffic Flow Prediction "with Rainfall Impact" Using Deep Learning (۲۰۲۱)
ترکیب Autoencoder و SVR برای پیش‌پردازش داده‌های چندمنبعی	مدل ترکیبی دقیق‌تر و پایدارتر از روش‌های سنتی بود.	داده‌های ویدئو، GPS، حسگر جاده‌ای	Autoencoder + SVR	Traffic Speed "Prediction Based on Deep" Feature Fusion" (۲۰۲۲)
اثبات کارایی مدل‌های هیبریدی در داده‌های چندمنبعی و شرایط واقعی شهری	کاهش خطا نسبت به مدل‌های منفرد LSTM و XGBoost حدود ۹٪-۱۲٪؛ پایداری در شرایط پرتراffic و داده‌های نویزی	سرعت وسایل نقلیه و GPS، یکی از شهرهای آفریقا	LSTM + XGBoost (مدل ترکیبی)	Urban Traffic Prediction Using Hybrid XGBoost-LSTM Model" (۲۰۲۰)
اهمیت ترانسفورمرها و یادگیری گراف تطبیقی در مدل‌سازی داده‌های پیچیده ترافیکی	بهبود معیارهای MAE و RMSE نسبت به ST-GCN و DCRNN؛ پایداری بهتر در پیش‌بینی بلندمدت	PEMS- و METR-LA BAY	Adaptive Graph Spatio-Temporal Transformer Network	Adaptive Graph Spatio-Temporal Transformer Network for Traffic Flow Forecasting
نشان‌دادن نقش کلیدی داده‌های جانبی در دقت پیش‌بینی در شرایط محیطی متغیر	بهبود MAE و RMSE نسبت به مدل‌های مرجع	داده‌های بزرگ شهری + متغیرهای جانبی (آب‌وهوا، POI و...)	Attribute-Augmented Spatio-Temporal GCN	AST-GCN: Attribute-Augmented Spatiotemporal Graph Convolutional Network for Traffic Forecasting (۲۰۲۰)
اهمیت بهینه‌سازی خودکار پارامترها در افزایش دقت و پایداری مدل‌های ML	MAPE ≈ ۲.۸۸٪ برای جریان ترافیک و ۳.۱۲٪ برای PCU؛ بهتر از مدل‌های پایه XGBoost، SVM و RF	داده‌های بزرگراه‌های شهری در چین	BO-XGBoost (Bayesian Optimization + XGBoost)	Prediction of High-Speed Traffic Flow around City Based on "BO-XGBoost" Model" (۲۰۲۳)
اهمیت استفاده از	عملکرد بهتر از GRU و	METR-LA و Hangst	Multi-Modal / Multi-Horizon BiLSTM + Soft	Incorporating Multivariate Auxiliary

اطلاعات جانبی و ساختار چندافقی با تعبیرپذیری بالا برای کاربردهای واقعی مدیریت ترافیک	MAE پایین‌تر؛ درک بهتر وابستگی‌های کوتاه‌مدت و بلندمدت	Attention	Information for Traffic Prediction on Highways (۲۰۲۳)
---	---	-----------	---

۲-۶- جمع بندی مطالعات و شکاف‌های پژوهشی

با توجه به بررسی مقالات داخلی و خارجی، می‌توان دریافت که پیش‌بینی جریان ترافیک یکی از حوزه‌های پویا و چندوجهی در سیستم‌های حمل‌ونقل هوشمند محسوب می‌شود. مطالعات انجام‌شده در سال‌های اخیر نشان می‌دهند که الگوریتم‌های یادگیری ماشین و یادگیری عمیق، به‌ویژه مدل‌های ترکیبی، عملکرد بهتری نسبت به روش‌های آماری سنتی در تحلیل داده‌های پیچیده و غیرخطی ترافیک از خود نشان داده‌اند.

مرور مطالعات داخلی و خارجی نشان داد که در سال‌های اخیر الگوریتم‌های یادگیری ماشین و یادگیری عمیق، به‌ویژه در قالب مدل‌های ترکیبی، جایگزین مناسبی برای روش‌های سنتی آماری در پیش‌بینی جریان ترافیک شده‌اند. الگوریتم‌هایی مانند XGBoost به دلیل سرعت و تفسیرپذیری، و مدل‌های عمیقی همچون LSTM، GRU و CNN به دلیل قدرت در استخراج ویژگی‌های زمانی و مکانی، بیشترین توجه پژوهشگران را به خود جلب کرده‌اند.

در میان الگوریتم‌های مورد بررسی، XGBoost به دلیل ویژگی‌هایی نظیر دقت بالا، قابلیت مقابله با داده‌های گمشده، پشتیبانی از داده‌های بزرگ و سرعت بالای اجرا، در بسیاری از مطالعات موفق‌تر از سایر روش‌های یادگیری ماشین ظاهر شده است. از سوی دیگر، مدل‌های LSTM و CNN نیز توانسته‌اند با بهره‌گیری از ساختارهای عمیق شبکه عصبی، وابستگی‌های زمانی و مکانی موجود در داده‌های ترافیکی را به‌خوبی مدل کنند. ترکیب این مدل‌ها در قالب ساختارهای هیبرید، مانند LSTM-XGBoost یا CNN-LSTM، در اکثر مطالعات موجب بهبود عملکرد شده است.

با این حال، بررسی مقالات نشان می‌دهد که در حوزه پیش‌بینی جریان ترافیک همچنان چالش‌ها و شکاف‌های پژوهشی متعددی وجود دارد که از جمله مهم‌ترین آن‌ها می‌توان به موارد زیر اشاره کرد:

- عدم توجه کافی به بازسازی داده‌های گمشده و نویزی در بسیاری از مطالعات، به‌ویژه هنگام استفاده از داده‌های واقعی شهری؛ بسیاری از مقالات تنها به حذف داده‌های ناقص پرداخته‌اند و کمتر به بازسازی پیشرفته (مانند Autoencoder یا KNN Imputation) توجه کرده‌اند. این موضوع به‌ویژه در داده‌های واقعی شهری یک چالش جدی است.
- استفاده محدود از داده‌های چندمنبعی (چندحسی یا چندبخشی) نظیر ترکیب GPS، آب‌وهوا، ANPRS و دوربین‌های نظارتی؛ هرچند برخی مطالعات از داده‌های GPS، حسگرهای جاده‌ای و آب‌وهوا استفاده کرده‌اند، اما ترکیب سیستماتیک داده‌های چندمنبعی هنوز محدود است. به‌ویژه در سناریوهای واقعی، داده‌های محیطی و رخدادهای شهری نقش مهمی در تغییر جریان ترافیک دارند.
- نبود ارزیابی دقیق تحت شرایط پرتراфик و غیرعادی مانند تصادف، بارندگی شدید یا رویدادهای شهری؛ اکثر پژوهش‌ها روی شرایط عادی متمرکز بوده‌اند و کمتر به پیش‌بینی در زمان وقوع حوادث، تصادفات، بارندگی شدید یا رویدادهای

ورزشی/اجتماعی پرداخته‌اند. در حالی که کاربرد عملی پیش‌بینی در همین شرایط بحرانی اهمیت بیشتری دارد.

- نیاز به بهینه‌سازی پارامترها با الگوریتم‌های پیشرفته‌تر مانند بهینه‌سازی بیزی برای مدل‌هایی مثل XGBoost؛ اگرچه روش‌هایی مانند Bayesian Optimization در برخی مطالعات (مانند BO-XGBoost) نتایج موفق‌تری داشته‌اند، اما در بسیاری از پژوهش‌ها پارامترها به‌صورت دستی یا با Grid Search تنظیم شده‌اند که می‌تواند دقت مدل را کاهش دهد.
- ضعف در تفسیرپذیری مدل‌های یادگیری عمیق در سناریوهای مدیریت ترافیک عملیاتی؛ مدل‌های عمیق با وجود دقت بالا، همچنان «جعبه سیاه» باقی مانده‌اند و برای استفاده عملی در مراکز کنترل ترافیک نیاز به روش‌های شفاف‌سازی و توضیح‌پذیری دارند.
- کاربردپذیری در سناریوهای واقعی شهری: بخش زیادی از تحقیقات روی دیتاست‌های عمومی مانند METR-LA و PEMS-BAY انجام شده است، اما هنوز مطالعات میدانی روی داده‌های بومی (به‌ویژه در کشورهای در حال توسعه) اندک است.

بر این اساس، در تحقیق حاضر تلاش خواهد شد تا با بهره‌گیری از مدل XGBoost و ترکیب آن با ساختارهای زمانی، همراه با تکنیک‌های بازسازی داده و انتخاب ویژگی، مدلی دقیق‌تر، پایدارتر و عملیاتی‌تر برای پیش‌بینی جریان ترافیک وسایل نقلیه هوشمند ارائه گردد. همچنین پژوهش حاضر تلاش می‌کند با تمرکز بر بازسازی داده‌های گمشده، ترکیب دو الگوریتم LSTM و XGBoost، و استفاده از دیتاست معتبر METR-LA، مدلی دقیق‌تر و پایدارتر برای پیش‌بینی جریان ترافیک ارائه دهد. این رویکرد می‌تواند هم از مزایای مدل‌های عمیق در استخراج وابستگی‌های زمانی بهره‌برد و هم از قدرت XGBoost در یادگیری روابط غیرخطی و مدیریت داده‌های گمشده استفاده کند.

۲-۷- جمع بندی فصل

در این فصل، ابتدا مفاهیم کلیدی مرتبط با پیش‌بینی جریان ترافیک، سیستم‌های حمل‌ونقل هوشمند، الگوریتم‌های یادگیری ماشین و یادگیری عمیق معرفی شدند. سپس روش‌های مختلف مورد استفاده در پیش‌بینی جریان ترافیک در قالب دسته‌بندی‌های سنتی، یادگیری ماشین، یادگیری عمیق و مدل‌های ترکیبی مورد بررسی قرار گرفتند. الگوریتم XGBoost به‌عنوان یکی از مؤثرترین روش‌های تقویت‌گرادیان، به دلیل دقت بالا، سرعت اجرا و قابلیت تفسیرپذیری، جایگاه ویژه‌ای در مطالعات اخیر یافته است. همچنین مدل‌های یادگیری عمیق مانند LSTM و CNN توانسته‌اند در استخراج ویژگی‌های زمانی و مکانی عملکرد مطلوبی ارائه دهند.

در بخش مرور مطالعات، مجموعه‌ای از پژوهش‌های داخلی و خارجی تحلیل شد. نتایج این تحلیل‌ها نشان داد که مدل‌های ترکیبی مانند XGBoost-LSTM، با بهره‌گیری از مزایای دو رویکرد کلاسیک و عمیق، می‌توانند عملکرد بهتری در شرایط پیچیده ترافیکی داشته باشند. همچنین توجه به داده‌های چندمنبعی و بازسازی داده‌های ناقص به‌عنوان فاکتورهای مهم در

بهبود دقت پیش‌بینی مطرح شدند. در نهایت، شکاف‌های پژوهشی شناسایی‌شده در ادبیات، از جمله ضعف در مدیریت داده‌های گمشده، کم‌توجهی به داده‌های ترکیبی محیطی و مکانی-زمانی، و محدودیت در تعمیم‌پذیری مدل‌ها در شرایط بحرانی، نشان‌دهنده نیاز به توسعه مدل‌هایی دقیق‌تر، مقاوم‌تر و انعطاف‌پذیرتر است. در فصل بعد، به تشریح مدل پیشنهادی تحقیق پرداخته خواهد شد که با تکیه بر این یافته‌ها طراحی شده است.

فصل ۳:

روش تحقیق

۳-۱- مقدمه

در این فصل، به تشریح روش تحقیق و طراحی مدل پیشنهادی جهت پیش‌بینی جریان ترافیک بر پایه داده‌های واقعی پرداخته می‌شود. هدف اصلی این پژوهش، توسعه یک مدل ترکیبی هوشمند مبتنی بر یادگیری ماشین و یادگیری عمیق است که بتواند با بهره‌گیری از الگوهای زمانی موجود در داده‌های ترافیکی و استفاده از الگوریتم‌های پیشرفته، دقت و پایداری پیش‌بینی را نسبت به روش‌های متداول بهبود بخشد.

با توجه به ساختار پیچیده و دینامیک جریان ترافیک، استفاده از الگوریتم‌های منفرد به‌ویژه در شرایط واقعی داده، اغلب با محدودیت‌هایی در دقت پیش‌بینی مواجه است. [۱] از این‌رو، در این تحقیق، ترکیب دو رویکرد قدرتمند مدنظر قرار گرفته است: الگوریتم LSTM برای مدل‌سازی وابستگی‌های زمانی و استخراج ویژگی‌های عمیق از داده‌های سری‌زمانی، و الگوریتم XGBoost برای انجام پیش‌بینی نهایی به‌عنوان یک تقویت‌کننده مبتنی بر درخت تصمیم که قابلیت مقابله با داده‌های نویزی، گمشده و چندبعدی را داراست. [۲۵]

برای پیاده‌سازی این مدل، از داده‌های واقعی دیتاست METR-LA استفاده شده است که شامل اطلاعات سرعت وسایل نقلیه در بازه‌های زمانی ۵ دقیقه‌ای از سنسورهای متعدد مستقر در شبکه جاده‌ای شهر لس‌آنجلس است. این داده‌ها در قالب ماتریس مکانی-زمانی ارائه شده و چالش‌هایی همچون داده‌های گمشده، نویزی و وابستگی‌های پیچیده مکانی و زمانی را در بر دارد که سبب اهمیت بیشتر انتخاب روش مناسب برای پیش‌بینی می‌شود. [۳۲]

مدل پیشنهادی با طی کردن مراحل مختلف شامل پیش‌پردازش داده‌ها، بازسازی مقادیر گمشده، استخراج ویژگی‌های زمانی با LSTM، و انجام پیش‌بینی با XGBoost طراحی شده است. به‌منظور ارزیابی دقت و کارایی مدل، از معیارهای MAE، RMSE، MAPE و R^2 استفاده خواهد شد. همچنین برای بررسی ارزش ترکیب LSTM و XGBoost، نتایج این مدل با عملکرد مدل پایه XGBoost به‌صورت مستقل مقایسه خواهد شد.

روش تحقیق در این پژوهش به‌گونه‌ای طراحی شده است که علاوه بر ارائه یک مدل ترکیبی دقیق برای پیش‌بینی جریان ترافیک، چارچوبی نظام‌مند برای مراحل جمع‌آوری داده، آماده‌سازی، طراحی مدل و ارزیابی نتایج فراهم کند. در این راستا، تأکید ویژه بر روی دو موضوع بوده است:

۱. کاربرپذیری در شرایط واقعی شهری؛ یعنی داده‌های مورد استفاده واقعی، پر از نویز و گمشده هستند و نیاز به بازسازی دقیق دارند.
 ۲. استفاده از مزایای مدل‌های مکمل؛ به این معنا که LSTM توانایی مدل‌سازی وابستگی‌های زمانی را دارد و XGBoost در کشف روابط غیرخطی و مقابله با داده‌های گمشده قوی عمل می‌کند.
- این فصل در ادامه به معرفی دقیق داده‌ها، مراحل پیش‌پردازش، طراحی مدل‌ها، معیارهای

ارزیابی و ابزارهای پیاده‌سازی می‌پردازد. در ادامه این فصل، مراحل گام‌به‌گام جمع‌آوری داده، آماده‌سازی، طراحی مدل و پیاده‌سازی روش پیشنهادی به تفصیل ارائه خواهد شد. بنابراین این فصل چارچوبی یکپارچه برای استفاده هم‌زمان از مدل‌های یادگیری عمیق و یادگیری ماشین در پیش‌بینی جریان ترافیک ارائه می‌دهد که از یک‌سو بر مبنای داده‌های واقعی آزمایش می‌شود و از سوی دیگر قابلیت تعمیم به محیط‌های عملیاتی را دارد.

۳-۲- تعریف مسئله و ساختار کلی مدل پیشنهادی

۳-۲-۱- تعریف دقیق مسئله

مسئله تحقیق حاضر، طراحی مدلی برای پیش‌بینی جریان ترافیک در شبکه جاده‌ای شهر لس‌آنجلس است. در این پژوهش، از داده‌های دیتاست METR-LA شامل اطلاعات ثبت‌شده توسط ۲۰۷ سنسور جاده‌ای در بازه‌های زمانی ۵ دقیقه‌ای استفاده گردید. هدف اصلی، بهبود دقت پیش‌بینی با بهره‌گیری از ترکیب دو مدل مکمل است:

- LSTM برای استخراج وابستگی‌های زمانی از داده‌های سری زمانی،
- XGBoost برای انجام پیش‌بینی نهایی بر اساس ویژگی‌های استخراج‌شده.

مدل پیشنهادی با تلفیق توانایی LSTM در مدل‌سازی روابط طولانی‌مدت زمانی و قابلیت XGBoost در شناسایی روابط غیرخطی و مدیریت داده‌های گمشده، رویکردی دقیق‌تر و پایدارتر برای پیش‌بینی جریان ترافیک ارائه می‌دهد.

۳-۲-۲- ساختار کلی مدل پیشنهادی


مدل پیشنهادی تحقیق شامل چهار مرحله اصلی است:

۱. پیش‌پردازش داده‌ها:
 - نرمال‌سازی داده‌ها
 - مدیریت داده‌های گمشده (بازسازی با میانگین متحرک یا روش‌های پیشرفته‌تر)
 - تبدیل ساختار داده به قالب ورودی مدل LSTM
۲. استخراج ویژگی‌های زمانی با LSTM:
 - طراحی مدل LSTM برای یادگیری الگوهای زمانی
 - استفاده از لایه‌های خروجی میانی یا نهایی به عنوان ویژگی‌های استخراج‌شده
۳. پیش‌بینی با XGBoost:
 - استفاده از ویژگی‌های خروجی LSTM به عنوان ورودی مدل XGBoost

- آموزش مدل و تنظیم پارامترها با استفاده از Cross-Validation یا بهینه‌سازی بیزی
- ۴. ارزیابی و مقایسه عملکرد:
 - با استفاده از معیارهایی چون R^2 ، MAPE، RMSE، MAE
 - مقایسه عملکرد مدل ترکیبی با مدل پایه XGBoost

به طور خلاصه، ساختار کلی مدل پیشنهادی از یک زنجیره‌ی چهار مرحله‌ای تشکیل شده است که در آن داده‌های خام ابتدا پاک‌سازی، بازسازی و نرمال‌سازی شده و به قالب مناسب برای مدل‌سازی تبدیل می‌شوند. سپس شبکه LSTM با هدف استخراج وابستگی‌های زمانی و شناسایی الگوهای نهفته در داده‌های سری‌زمانی به کار گرفته می‌شود. خروجی این شبکه، بردارهایی از ویژگی‌های زمانی است که در مرحله‌ی سوم به الگوریتم XGBoost داده می‌شوند تا پیش‌بینی نهایی با دقت و پایداری بالاتر انجام گیرد. در نهایت، عملکرد مدل ترکیبی با استفاده از مجموعه‌ای از شاخص‌های ارزیابی معتبر سنجیده شده و نتایج آن با مدل‌های منفرد مقایسه می‌شود. این طراحی ماژولار موجب می‌گردد هر بخش از مدل به‌طور مستقل بهینه‌سازی شده و در عین حال ترکیب آن‌ها یک چارچوب جامع و کارآمد برای پیش‌بینی جریان ترافیک فراهم آورد.

۳-۲-۳- دیاگرام کلی مدل پیشنهادی



دیاگرام فوق نشان می‌دهد که جریان پردازش داده‌ها در مدل پیشنهادی به‌صورت یک خط لوله (Pipeline) مرحله‌ای طراحی شده است. در این خط لوله، داده‌های خام پس از پیش‌پردازش، وارد مدل LSTM می‌شوند تا ویژگی‌های زمانی استخراج گردند. سپس این ویژگی‌ها به الگوریتم XGBoost داده می‌شوند تا پیش‌بینی نهایی انجام شود. در نهایت خروجی مدل با استفاده از شاخص‌های ارزیابی استاندارد نظیر MAE، RMSE، MAPE و R² سنجیده می‌شود. این ساختار علاوه بر وضوح مراحل، نشان می‌دهد که مدل پیشنهادی یکپارچه اما ماژولار طراحی شده است و امکان بهینه‌سازی یا جایگزینی هر بخش به‌صورت مستقل وجود دارد.

۳-۳- معرفی داده‌ها و ویژگی‌های مورد استفاده

۳-۳-۱- معرفی دیتاست METR-LA

دیتاست METR-LA یکی از مشهورترین و پرکاربردترین مجموعه‌داده‌های عمومی در حوزه پیش‌بینی جریان ترافیک است که توسط اداره حمل‌ونقل لس‌آنجلس (LA DOT) جمع‌آوری و منتشر شده است. این مجموعه داده به دلیل پوشش وسیع، کیفیت بالا و

استانداردسازی، در بسیاری از پژوهش‌های بین‌المللی به‌عنوان مرجع اصلی استفاده می‌شود. ویژگی‌های اصلی این دیتاست عبارتند از:

- تعداد حسگرها (گره‌ها): ۲۰۷ حسگر مستقر در بزرگراه‌های اصلی شهر لس‌آنجلس.
- بازه زمانی: از ۱ مارس تا ۳۰ ژوئن ۲۰۱۲ (حدود ۴ ماه).
- فواصل نمونه‌برداری: هر ۵ دقیقه یک بار؛ در نتیجه بیش از ۳۴,۰۰۰ رکورد زمانی برای هر حسگر ثبت شده است.
- متغیر اندازه‌گیری‌شده: سرعت لحظه‌ای وسایل نقلیه (بر حسب مایل بر ساعت).
- ساختار داده: ماتریس مکانی-زمانی که سطرها نمایانگر حسگرها و ستون‌ها نشان‌دهنده تایم‌استمپ‌ها هستند.
- از آن‌جا که داده‌ها از محیط واقعی جمع‌آوری شده‌اند، برخی مشکلات ذاتی در آن‌ها وجود دارد:
- داده‌های گمشده: بخش قابل توجهی از رکوردها (بین ۵ تا ۱۵٪) فاقد داده هستند که ناشی از خطای حسگر یا مشکلات ارتباطی است.
- نویز داده‌ها: وجود مقادیر غیرمنطقی یا پرت (outlier) به دلیل شرایط خاص مانند تصادف یا اختلال حسگر.
- ناهمگنی مکانی: هر حسگر شرایط متفاوتی از جمله تعداد خطوط، تراکم خودرو و موقعیت جغرافیایی را پوشش می‌دهد.

دلیل انتخاب این دیتاست برای پژوهش حاضر آن است که:

۱. یکی از معتبرترین مجموعه‌های عمومی برای تحقیقات ترافیک محسوب می‌شود.
۲. حجم بالای داده و پوشش طولانی‌مدت آن امکان آموزش مدل‌های یادگیری عمیق را فراهم می‌کند.
۳. چالش‌های واقعی مانند داده‌های گمشده و نویزی را شامل می‌شود و در نتیجه می‌تواند قدرت مدل پیشنهادی را در شرایط واقعی بیازماید.

۲-۳-۳- آمار توصیفی داده‌ها

برای درک بهتر ویژگی‌های مجموعه داده METR-LA، آمار توصیفی آن بررسی شده است. این آمار نشان می‌دهد:

- میانگین سرعت ثبت‌شده: حدود ۶۰ کیلومتر بر ساعت با انحراف معیار نسبتاً بالا به دلیل تغییرات در ساعات اوج.
- حداکثر سرعت مشاهده‌شده: نزدیک به ۱۲۰ کیلومتر بر ساعت (مطابق شرایط آزادراهی).
- حداقل سرعت: نزدیک به صفر کیلومتر بر ساعت در زمان‌های اوج ترافیک و وقوع رخدادهای.
- درصد داده‌های گمشده: بسته به حسگر بین ۵ تا ۱۵ درصد متغیر بوده است.
- توزیع زمانی داده‌ها: الگوهای روزانه و هفتگی واضحی در داده‌ها قابل مشاهده است، به‌گونه‌ای که ساعات اوج صبحگاهی (۷ تا ۹ صبح) و عصرگاهی (۵ تا ۷ عصر) بیشترین تغییرات را دارند.

این آمار توصیفی نه تنها نمایی کلی از کیفیت داده‌ها ارائه می‌دهد، بلکه اهمیت استفاده از روش‌های مقاوم در برابر نویز و داده‌های ناقص را در پیش‌بینی جریان ترافیک برجسته می‌سازد.

۳-۳-۳- ساختار داده‌ها

ساختار داده‌های METR-LA به گونه‌ای است که هر حسگر به صورت یک سری زمانی مستقل داده تولید می‌کند. در نتیجه مجموعه داده یک ماتریس دوبرخی (گره $\times$ زمان) را تشکیل می‌دهد. در هر ردیف این ماتریس داده‌های یک حسگر و در هر ستون داده‌های مربوط به یک تایم‌استمپ وجود دارد. چنین ساختاری امکان تحلیل هم‌زمان روابط مکانی (بین حسگرها) و زمانی (بین تایم‌استمپ‌ها) را فراهم می‌سازد. علاوه بر این، وجود ۳۴'۲۷۲ تایم‌استمپ باعث می‌شود داده‌ها برای آموزش مدل‌های یادگیری عمیق با دقت کافی مناسب باشند.

- تعداد سنسورها (گره‌ها): ۲۰۷
- تعداد تایم‌استمپ‌ها: حدود ۳۴'۲۷۲ مقدار برای هر سنسور (معادل حدود ۴ ماه، ۵ دقیقه‌ای)
- نوع داده‌ها: عددی (سرعت لحظه‌ای)
- ویژگی هدف: پیش‌بینی سرعت جریان ترافیک در آینده نزدیک (مثلاً ۱۵ یا ۳۰ دقیقه آینده)

۳-۳-۴- داده‌های گمشده نویزی

از آنجا که داده‌ها در محیط واقعی و از حسگرهای شهری جمع‌آوری شده‌اند، وجود داده‌های گمشده (missing values) امری طبیعی است. در این تحقیق، ابتدا نرخ فقدان داده در هر سنسور بررسی شده و برای مدیریت داده‌های گمشده از روش‌های بازسازی نظیر:

- میانگین متحرک (Moving Average Imputation)
- یا در مراحل پیشرفته‌تر: مدل‌های یادگیری برای بازسازی (Autoencoder یا KNN) استفاده شده است.

بررسی اولیه داده‌ها نشان داد که میانگین نرخ فقدان داده در سنسورها بین ۵ تا ۱۵ درصد است. اگر این داده‌های گمشده بدون بازسازی حذف شوند، حجم مؤثری از داده از دست خواهد رفت و دقت مدل کاهش می‌یابد. بنابراین بازسازی داده‌های گمشده اهمیت زیادی دارد. در این تحقیق ابتدا روش ساده میانگین متحرک به کار گرفته شد تا مقادیر گمشده بر اساس همسایگی زمانی جایگزین شوند. سپس برای افزایش دقت، روش‌های مبتنی بر یادگیری مانند KNN Imputation و Autoencoder نیز مورد توجه قرار گرفتند تا امکان مقایسه فراهم شود. از سوی دیگر، داده‌های پرت (Outliers) مانند سرعت صفر در بزرگراه

یا سرعت‌های بالاتر از ۱۲۰ مایل بر ساعت شناسایی و اصلاح شدند.

۵-۳-۳- انتخاب ویژگی‌ها

در این تحقیق، از داده‌های سرعت سنسورها در بازه‌های قبلی زمانی (lagged values) به‌عنوان ویژگی‌های ورودی استفاده شده است. برای مثال، جهت پیش‌بینی سرعت در تایم t ، از مقادیر سنسورهای قبلی در بازه‌های $(t-1, t-2, \dots, t-n)$ به‌عنوان ورودی استفاده می‌شود.

همچنین متغیرهای زمانی کمکی مانند:

- ساعت روز
- روز هفته

نیز به مدل افزوده شده‌اند تا بهبود دقت مدل در تشخیص الگوهای ترافیکی کمک کند. در انتخاب ویژگی‌ها، علاوه بر lag‌های زمانی $(t-1, t-2, \dots, t-n)$ ، دو نوع ویژگی دیگر نیز لحاظ شد:

(۱) ویژگی‌های زمانی (Temporal Features): شامل ساعت روز و روز هفته، که الگوهای دوره‌ای ترافیک (ساعات اوج و روزهای تعطیل) را مدل می‌کنند.

(۲) ویژگی‌های مکانی (Spatial Features): هرچند در این نسخه تحقیق به‌طور کامل استفاده نشده، اما وابستگی مکانی بین حسگرهای مجاور نیز در قالب داده‌های تکمیلی قابل تعریف است. وجود این ویژگی‌ها کمک می‌کند مدل توانایی بیشتری در درک الگوهای پیچیده داشته باشد.

۶-۳-۳- آماده‌سازی نهایی داده‌ها

پس از بازسازی مقادیر گمشده و انتخاب ویژگی‌های زمانی، داده‌ها به دو بخش:

- داده‌های ورودی برای LSTM (به‌صورت توالی زمانی)
- ویژگی‌های استخراج‌شده برای XGBoost

تقسیم شده‌اند. سپس با نرمال‌سازی مقادیر (Min-Max Scaling) آماده آموزش مدل شده‌اند.

پس از بازسازی داده‌های گمشده و انتخاب ویژگی‌ها، داده‌ها در چند گام آماده شدند:

(۱) تقسیم داده‌ها به ورودی و خروجی: داده‌های سری زمانی به پنجره‌های ۱۲ تایم‌استپی تقسیم شدند (معادل یک ساعت گذشته). برچسب خروجی مقدار سرعت در گام بعدی (۵ دقیقه آینده) بود.

۲) ورودی برای LSTM: داده‌ها به قالب سه‌بعدی (نمونه $\times$ زمان $\times$ ویژگی) تبدیل شدند تا قابلیت استفاده در لایه بازگشتی LSTM را داشته باشند.

۳) ویژگی‌های ورودی XGBoost: خروجی لایه‌های میانی LSTM به‌عنوان بردار ویژگی به مدل XGBoost منتقل شد.

۴) نرمال‌سازی: داده‌ها با روش Min-Max Scaling در بازه [۰, ۱] نرمال‌سازی شدند و برای گزارش نتایج، وارون‌سازی نرمال‌سازی انجام شد تا معیارهای خطا در مقیاس واقعی ترافیک بیان شوند.

۴-۳- پیش‌پردازش داده‌ها

با توجه به ماهیت داده‌های واقعی ترافیک، مرحله پیش‌پردازش نقش بسیار مهمی در کیفیت نهایی مدل پیش‌بینی دارد. مراحل انجام‌شده در این تحقیق به‌صورت گام‌به‌گام عبارتند از:

(۱) مدیریت داده‌های گمشده:

داده‌های گمشده ابتدا با جایگزینی مقادیر صفر با NaN مشخص شدند. سپس برای بازسازی مقادیر گمشده از دو روش استفاده شد:

- میانگین متحرک (Moving Average Imputation): جایگزینی مقدار هر نقطه گمشده با میانگین مقادیر قبلی و بعدی.
- KNN Imputation (برای آزمایش تکمیلی): جایگزینی داده‌های گمشده بر اساس شباهت به حسگرهای مجاور.

۲) حذف داده‌های پرت (Outlier Detection): مقادیر غیرمنطقی مانند سرعت‌های نزدیک به صفر یا بالاتر از ۱۲۰ مایل بر ساعت، به‌عنوان داده پرت شناسایی و حذف یا بازسازی شدند.

۳) نرمال‌سازی داده‌ها:

برای همسان‌سازی مقیاس داده‌ها و جلوگیری از غلبه ویژگی‌ها با مقادیر بزرگ‌تر، از روش Min-Max Scaling در بازه [۰, ۱] استفاده شد.

۴) ساخت توالی‌های زمانی:

برای آموزش LSTM، داده‌ها به توالی‌هایی با طول ۱۲ تایم‌استپ (معادل یک ساعت گذشته) تقسیم شدند. هر نمونه ورودی شامل ۱۲ مقدار قبلی و خروجی معادل مقدار سرعت در تایم بعدی بود.

- ۵) افزودن ویژگی‌های کمکی (Feature Engineering):
- ویژگی‌های زمانی: ساعت روز و روز هفته به‌صورت متغیرهای کمکی به مدل افزوده شدند تا اثر الگوهای دوره‌ای ترافیک بهتر نمایان شود.
 - ویژگی‌های مکانی (در مرحله آزمایشی): برای برخی مدل‌ها فاصله مکانی بین حسگرها نیز لحاظ شد.

۳-۵- طراحی مدل پیشنهادی

با توجه به ساختار پیچیده و دینامیک جریان ترافیک در محیط‌های شهری، استفاده از مدل‌های منفرد یادگیری ماشین یا یادگیری عمیق به‌تنهایی ممکن است در استخراج الگوهای دقیق با چالش‌هایی روبه‌رو باشد. در همین راستا، این تحقیق یک مدل ترکیبی پیشنهادی بر پایه LSTM و XGBoost ارائه می‌دهد که هدف آن، افزایش دقت، پایداری و قابلیت تعمیم در پیش‌بینی جریان ترافیک است.

۳-۵-۱- معماری مدل ترکیبی

مدل پیشنهادی شامل دو بخش اصلی است:

- (۱) بخش LSTM برای استخراج ویژگی‌های زمانی
 - ورودی به این بخش، توالی زمانی مقادیر سرعت در چند تایم‌استپ گذشته (مثلاً ۱۲ تایم‌استپ گذشته معادل یک ساعت) است.
 - مدل LSTM با یک یا دو لایه بازگشتی، الگوهای زمانی نهفته را شناسایی می‌کند.
 - خروجی این شبکه (وکتور ویژگی‌های زمانی) برای پیش‌بینی نهایی به مدل دوم منتقل می‌شود.
- (۲) بخش XGBoost برای پیش‌بینی نهایی
 - خروجی LSTM به‌عنوان ویژگی‌های ورودی به مدل XGBoost داده می‌شود.
 - مدل XGBoost براساس این ویژگی‌ها مقدار سرعت ترافیک در بازه زمانی آینده (مثلاً ۱۵ یا ۳۰ دقیقه بعد) را پیش‌بینی می‌کند.
 - پارامترهای XGBoost از طریق تکنیک Grid Search یا بهینه‌سازی بیزی (Bayesian Optimization) تنظیم می‌شود.

در واقع ایده اصلی این معماری بر آن است که LSTM به‌عنوان یک استخراج‌کننده ویژگی زمانی عمل کند و الگوهای نهفته در سری‌های زمانی را شناسایی نماید. سپس این ویژگی‌های استخراج‌شده به XGBoost منتقل می‌شوند که قادر است روابط غیرخطی پیچیده را در داده‌ها بیاموزد. این طراحی دو مرحله‌ای موجب می‌شود که نقاط قوت هر دو مدل در کنار هم قرار گرفته و محدودیت‌های آن‌ها تا حدی جبران گردد. چنین ساختاری به‌ویژه در داده‌های واقعی شهری که با نویز و مقادیر گم‌شده مواجه‌اند، دقت و پایداری بالاتری ایجاد می‌کند.

۳-۵-۲- طراحی مدل LSTM

فرمول بندی ساده

در این پژوهش، پیش‌بینی جریان/سرعت ترافیک به‌صورت *sequence-to-one* انجام شده است. یک پنجره‌ی زمانی با طول w (در پیکربندی پایه $w = 12$ معادل ۶۰ دقیقه گذشته با گام‌های ۵ دقیقه‌ای) به‌عنوان ورودی به شبکه داده می‌شود و خروجی مدل مقدار $t + \hat{h}y$ برای افق زمانی h را برمی‌گرداند. در پیکربندی پایه، $h = 1$ (پیش‌بینی ۵ دقیقه بعد) است و در سناریوهای توسعه، $h \in \{3, 6\}$ (افق‌های ۱۵ و ۳۰ دقیقه) نیز آزموده می‌شود. ورودی‌ها شامل سری سرعت حسگر هدف و ویژگی‌های کمکی زمانی (ساعت روز، روز هفته) هستند.

معماری شبکه

معماری پایه‌ی LSTM با هدف توازن میان دقت و هزینه‌ی محاسباتی طراحی شده است:

- **ورودی:** بردار $\mathbb{R} \in X$ $(feat^{\omega \times n})$ که شامل ω مشاهده متوالی و $feat^n$ (سرعت حسگر + ویژگی‌های زمانی) ویژگی است
- **لایه LSTM:** یک لایه با ۶۴ واحد بازگشتی و تابع فعال‌سازی $\tanh$ با خروجی h_t
- **Dropout:** با نرخ ۰.۲ به‌منظور کاهش بیش‌برازش.
- **Dense خروجی:** یک نورون با فعال‌سازی خطی برای بازگرداندن مقدار پیش‌بینی‌شده $t + \hat{h}y$

پیکربندی‌های جایگزین آزموده‌شده شامل:

- افزایش/کاهش تعداد واحدهای LSTM (۳۲، ۶۴، ۱۲۸)
- استفاده از معماری دومرحله‌ای (دو لایه LSTM متوالی با `(return_sequences=True)`)
- به‌کارگیری منظم‌سازی L_2 با ضریب $\lambda = 10^{-4}$

راهبرد آموزش

- **تابع زیان:** میانگین مربعات خطا (MSE) برای هم‌راستایی با معیارهای گزارش‌شده.
- **بهینه‌ساز:** Adam با نرخ یادگیری اولیه 10^{-3}
- **اعتبارسنجی:** تقسیم داده‌ها به‌صورت زمانی (۸۰٪ آموزش، ۲۰٪ آزمون) و جداسازی ۱۰٪ از انتهای آموزش برای validation.
- **تنظیمات: Regularization**
 - EarlyStopping با $patience = 8$ بر اساس MSE اعتبارسنجی
 - ReduceLROnPlateau با فاکتور ۰.۵ و حداقل نرخ یادگیری 10^{-6}
- **پارامترهای اجرایی:** $batch\ size = 128$ ، حداکثر ۵۰ epoch، بدون shuffle برای حفظ ترتیب زمانی.

مهندسی ویژگی‌ها

- **توالی‌های ورودی:** $[y_t, \dots, y_{t-\omega+1}]$ به همراه ویژگی‌های کمکی ساخته شد.
- **ویژگی‌های زمانی:** ساعت روز و روز هفته با تبدیل‌های سینوسی-کسینوسی برای مدل‌سازی ماهیت تناوبی.

- **نرمال‌سازی: Min-Max** بر اساس بخش آموزشی؛ برای گزارش نتایج، مقادیر پیش‌بینی‌شده به مقیاس اصلی برگردانده شدند.

جلوگیری از بیش‌برازش

- به‌کارگیری Dropout و L^2 -Regularization ،
- استفاده از Early Stopping و کاهش پویا نرخ یادگیری،
- مقایسه‌ی عملکرد آموزش/اعتبارسنجی در طول epochs

ارزیابی و اعتبارسنجی

- ارزیابی نهایی روی بخش آزمون نگه‌داشته‌شده انجام شد.
- به‌صورت تکمیلی، روش walk-forward با پنجره‌ی گسترنده (expanding window) نیز آزموده شد.
- معیارها: MAE ، MSE ، RMSE ، MAPE و R^2

شبه‌کد فرآیند آموزش

۱. تقسیم داده‌ها به Train/Val/Test به‌صورت زمانی.
۲. ساخت توالی‌های ورودی با طول w و برجسب y_{h+t}
۳. نرمال‌سازی بر اساس داده‌های آموزشی.
۴. آموزش LSTM با پایش MSE در اعتبارسنجی.
۵. انتخاب بهترین وزن‌ها (checkpoint).
۶. ارزیابی روی Test و گزارش خطاها.

۳-۵-۳- طراحی مدل XGBoost

معرفی الگوریتم

الگوریتم **XGBoost (Extreme Gradient Boosting)** یک روش تقویت گرادیانی مبتنی بر درخت‌های تصمیم است که با ایجاد مجموعه‌ای از درخت‌های ضعیف (Weak Learners) و ترکیب آن‌ها، مدلی قدرتمند و مقاوم در برابر داده‌های نویزی و ناقص می‌سازد. ویژگی مهم XGBoost آن است که علاوه بر دقت بالا، توانایی مدیریت داده‌های گمشده و کنترل بیش‌برازش از طریق منظم‌سازی (Regularization) را دارد.

داده‌های ورودی

ورودی مدل XGBoost در این پژوهش بردار ویژگی‌هایی است که از خروجی لایه‌های میانی LSTM استخراج شده‌اند. به بیان دیگر، LSTM الگوهای زمانی را یاد می‌گیرد و ویژگی‌های نهفته را تولید می‌کند؛ سپس این ویژگی‌ها به‌عنوان ورودی XGBoost برای پیش‌بینی مقدار سرعت در افق زمانی آینده به‌کار می‌روند.

پارامترهای کلیدی

برای آموزش مدل XGBoost ، مجموعه‌ای از هایپرپارامترها تنظیم شد که مهم‌ترین آن‌ها

عبارتند از:

- **max_depth**: حداکثر عمق درخت (۳ تا ۱۰، برای کنترل پیچیدگی مدل).
- **learning_rate**: نرخ یادگیری (۰.۰۱ تا ۰.۳).
- **n_estimators**: تعداد درخت‌ها (۵۰۰ تا ۱۰۰).
- **subsample**: نسبت نمونه‌های انتخابی برای ساخت هر درخت (۰.۶ تا ۱).
- **colsample_bytree**: نسبت ویژگی‌های انتخابی در هر درخت (۰.۶ تا ۱).
- **lambda (L^۲ regularization)**: ضریب جریمه برای کنترل بیش‌برازش.

روش تنظیم پارامترها

برای یافتن بهترین مقادیر پارامترها از دو روش استفاده شد:

- (۱) **Grid Search** با **Cross-Validation** **پنج‌تایی (۵-Fold CV)**: برای جستجوی سیستماتیک روی فضای پارامترها.
- (۲) **Bayesian Optimization**: برای جستجوی کاراتر و سریع‌تر در فضای پارامترها با در نظر گرفتن روابط احتمالی بین آن‌ها.

فرآیند آموزش

۱. داده‌های ویژگی خروجی از LSTM به‌عنوان ورودی به XGBoost داده شدند.
۲. مدل XGBoost با مجموعه‌ای از پیکربندی‌ها آموزش داده شد.
۳. بهترین مدل بر اساس کمترین خطای اعتبارسنجی انتخاب شد.
۴. ارزیابی نهایی روی داده‌های آزمون انجام گرفت و معیارهای MAE، RMSE، MAPE و R^2 محاسبه شدند.

مزایا

- توانایی مدیریت داده‌های ناقص بدون نیاز به بازسازی کامل.
- انعطاف‌پذیری بالا در مدل‌سازی روابط غیرخطی.
- سرعت آموزش و پیش‌بینی بالا حتی روی داده‌های بزرگ.
- قابلیت تفسیرپذیری نسبت به مدل‌های عمیق.

۴-۵-۳- طراحی مدل ترکیبی (LSTM + XGBoost)

ایده اصلی

مدل‌های LSTM و XGBoost هر یک دارای نقاط قوت و ضعف خاص خود هستند. LSTM در استخراج وابستگی‌های زمانی و الگوهای متوالی داده‌های سری‌زمانی بسیار موفق عمل می‌کند، اما در برابر داده‌های نویزی و ناقص حساس است و آموزش آن زمان‌بر می‌باشد. در مقابل، XGBoost توانایی بالایی در مدیریت داده‌های غیرخطی و گمشده دارد، اما به‌تنهایی قادر به درک ساختارهای زمانی پیچیده نیست. ترکیب این دو رویکرد می‌تواند عملکرد کلی مدل را ارتقا دهد.

ساختار ترکیبی

۱. مرحله اول – LSTM:

- دریافت داده‌های ورودی به‌صورت توالی‌های زمانی (۱۲ گام قبلی).
- استخراج ویژگی‌های زمانی نهفته در داده‌ها.
- تولید بردار ویژگی به‌عنوان خروجی.

۲. مرحله دوم – XGBoost:

- دریافت بردار ویژگی خروجی LSTM به‌عنوان ورودی.
- مدل‌سازی روابط غیرخطی بین این ویژگی‌ها و متغیر هدف.
- تولید مقدار پیش‌بینی‌شده سرعت جریان ترافیک در افق زمانی آینده.

مزیت طراحی دو مرحله‌ای

- **جبران ضعف‌ها:** LSTM وابستگی‌های زمانی را به‌خوبی مدل می‌کند، در حالی‌که XGBoost مقاومت در برابر نویز و داده‌های ناقص را تضمین می‌کند.
- **بهبود دقت:** نتایج آزمایشی نشان داد که ترکیب این دو مدل باعث کاهش خطا نسبت به استفاده منفرد از هر کدام شد.
- **انعطاف‌پذیری:** این ساختار ماژولار امکان جایگزینی هر بخش با نسخه‌های پیشرفته‌تر مانند GRU یا LightGBM را فراهم می‌سازد.

فرآیند آموزش و ارزیابی

۱. تقسیم داده‌ها به آموزش، اعتبارسنجی و آزمون به‌صورت زمانی.
۲. آموزش LSTM و استخراج بردار ویژگی از داده‌های آموزشی.
۳. استفاده از این بردارها به‌عنوان ورودی برای XGBoost.
۴. تنظیم پارامترهای XGBoost با Cross-Validation یا بهینه‌سازی بیزی.
۵. ارزیابی مدل ترکیبی روی داده‌های آزمون و مقایسه نتایج با LSTM و XGBoost منفرد.

۵-۳-۵- مراحل طراحی و پیاده‌سازی

علاوه بر بازسازی داده‌های گمشده و نرمال‌سازی، در این مرحله داده‌های پرت نیز شناسایی و اصلاح شدند تا از تأثیرگذاری مقادیر غیرمنطقی بر آموزش مدل جلوگیری شود.

- (۱) پیش‌پردازش داده‌ها
 - نرمال‌سازی داده‌ها با Min-Max
 - بازسازی داده‌های گمشده با میانگین متحرک یا KNN
 - تبدیل داده‌ها به قالب دنباله‌ای برای ورودی LSTM

(۲) ساخت مدل LSTM

در طراحی LSTM از مکانیزم Dropout برای کاهش بیش‌برازش و از Early Stopping برای جلوگیری از آموزش بیش‌از حد استفاده شد. همچنین چند پیکربندی مختلف (۶۴ و ۱۲۸ نرون، یک‌لایه و دو‌لایه) مورد آزمایش قرار گرفت.

- تعداد تایم‌استپ‌های ورودی: ۱۲ (معادل ۱ ساعت گذشته)
- تعداد نوروها در لایه مخفی: ۶۴ یا ۱۲۸ (با آزمون چند پیکربندی)
- Dropout برای جلوگیری از overfitting
- خروجی: بردار ویژگی $n \times 1$

۳) ساخت مدل XGBoost

برای تنظیم بهینه پارامترها، علاوه بر Grid Search، روش Bayesian Optimization نیز پیاده‌سازی شد که سرعت جست‌وجوی فضای پارامترها را افزایش داده و از گرفتار شدن در مینیمم محلی جلوگیری می‌کند.

- ورودی: ویژگی‌های استخراج‌شده از LSTM
- پارامترها: 'max_depth', 'learning_rate', 'n_estimators', 'subsample'
- روش تنظیم: Grid Search یا Bayesian Optimization با ۵-fold Cross-Validation

۴) آموزش و ارزیابی مدل

تقسیم داده‌ها به صورت زمانی (Time-based Split) انجام شد تا از نشت اطلاعات جلوگیری شود. همچنین علاوه بر معیارهای اصلی، نمودارهای یادگیری (Learning Curves) نیز برای ارزیابی فرآیند آموزش رسم شدند.

- داده‌ها به دو بخش train و test تقسیم می‌شوند (مثلاً ۸۰/۲۰)
- مدل روی داده‌های آموزش آموزش داده می‌شود و روی داده‌های تست ارزیابی می‌شود

۶-۵-۳- مزایای ساختار پیشنهادی

- استخراج دقیق‌تر الگوهای زمانی با LSTM نسبت به روش‌های دستی یا ایستا
- افزایش دقت پیش‌بینی نهایی با XGBoost که توانایی یادگیری غیرخطی بالایی دارد
- کاهش حساسیت به داده‌های گم‌شده یا نویزی با استفاده از مدل مقاوم XGBoost
- سرعت بالاتر آموزش نسبت به مدل‌های عمیق تمام‌عیار (end-to-end)

بنابراین، مدل ترکیبی پیشنهادی نه تنها قادر است وابستگی‌های زمانی را با دقت بالا شناسایی کند، بلکه توانایی زیادی در مدیریت روابط غیرخطی و داده‌های نویزی دارد. این مزایا باعث می‌شود مدل در مقایسه با رویکردهای منفرد عملکرد پایدارتری داشته و برای پیاده‌سازی در سامانه‌های حمل‌ونقل هوشمند مناسب‌تر باشد.

۶-۳- معیارهای ارزیابی

برای ارزیابی عملکرد مدل‌ها در پیش‌بینی جریان ترافیک، از چهار معیار متداول در یادگیری ماشین و تحلیل سری‌های زمانی استفاده شد. این معیارها شامل میانگین قدرمطلق

خطا (MAE) ، میانگین مربعات خطا (MSE) ، ریشه میانگین مربعات خطا (RMSE) و میانگین درصد خطای مطلق (MAPE) به همراه ضریب تعیین (R^2) هستند.

۱. میانگین قدر مطلق خطا (MAE)
این معیار مقدار میانگین اختلاف مطلق بین مقادیر واقعی و پیش‌بینی‌شده را محاسبه می‌کند:

$$MAE = \sum_{i=1}^N \frac{1}{N} |y_i - \hat{y}_i|$$

که در آن y_i مقدار واقعی، $\hat{y}_i$ مقدار پیش‌بینی‌شده و N تعداد نمونه‌هاست. مقدار کمتر MAE نشان‌دهنده پیش‌بینی دقیق‌تر است.

۲. میانگین مربعات خطا (MSE)
MSE میانگین مجذور اختلاف بین مقادیر واقعی و پیش‌بینی‌شده را محاسبه می‌کند:

$$MSE = \sum_{i=1}^N \frac{1}{N} (y_i - \hat{y}_i)^2$$

این معیار خطاهای بزرگ را بیشتر جریمه می‌کند، بنابراین حساسیت بالایی به داده‌های پرت دارد.

۳. ریشه میانگین مربعات خطا (RMSE)
RMSE ریشه دوم MSE است و در همان مقیاس متغیر اصلی بیان می‌شود:

$$RMSE = \sqrt{\sum_{i=1}^N \frac{1}{N} (y_i - \hat{y}_i)^2}$$

RMSE برای تفسیر شهودی مناسب‌تر است زیرا واحد آن مشابه واحد داده‌ها (سرعت) است.

۴. میانگین درصد خطای مطلق (MAPE)
MAPE درصد میانگین خطای مطلق نسبت به مقدار واقعی را بیان می‌کند:

$$MAPE = \sum_{i=1}^N \frac{100}{N} \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

۵. ضریب تعیین R^2
این معیار میزان واریانس توضیح داده شده توسط مدل را نشان می‌دهد:

$$R^2 = \frac{(y_i - \hat{y}_i)^2 \sum_{i=1}^N}{(\bar{y} - y_i)^2 \sum_{i=1}^N} - 1$$

که در آن $\bar{y}$ میانگین مقادیر واقعی است. مقدار R^2 نزدیک به ۱ نشان‌دهنده برازش عالی مدل است

توضیحات تکمیلی برای متن:

- MAE و RMSE برای خطای مطلق و نسبی مناسب‌اند.
- MSE بیشتر برای مقایسه حساسیت مدل‌ها به خطاهای بزرگ به‌کار می‌رود.
- MAPE برای سنجش دقت نسبی مدل‌ها کاربرد دارد.
- R^2 میزان توانایی مدل در توضیح تغییرات داده‌ها را مشخص می‌کند.

۳-۷- جمع بندی فصل

در این فصل، به تشریح کامل روش تحقیق و طراحی مدل پیشنهادی برای پیش‌بینی جریان ترافیک پرداخته شد. ابتدا مسئله تحقیق به صورت رسمی تعریف گردید و ضرورت استفاده از رویکرد ترکیبی مورد بحث قرار گرفت. سپس ساختار کلی مدل ارائه شد که شامل دو بخش اصلی است:

۱. استخراج ویژگی‌های زمانی با استفاده از شبکه بازگشتی LSTM.

۲. پیش‌بینی نهایی با الگوریتم قدرتمند XGBoost.

هدف اصلی این ترکیب، بهره‌برداری هم‌زمان از توانایی LSTM در مدل‌سازی وابستگی‌های زمانی و قدرت XGBoost در پردازش روابط غیرخطی، مدیریت داده‌های گمشده و بهینه‌سازی پیش‌بینی است.

در ادامه، دیتاست معتبر METR-LA معرفی شد که شامل داده‌های واقعی سرعت وسایل نقلیه در بازه‌های زمانی ۵ دقیقه‌ای و جمع‌آوری شده از ۲۰۷ حسگر شهری در لس‌آنجلس است. سپس مراحل پیش‌پردازش داده‌ها شامل بازسازی مقادیر گمشده، شناسایی داده‌های پرت، نرمال‌سازی و انتخاب ویژگی‌های زمانی به تفصیل بیان گردید تا بستر مناسبی برای ورود داده‌ها به مدل‌های یادگیری ایجاد شود.

در بخش طراحی مدل، معماری شبکه LSTM و نحوه استخراج بردارهای ویژگی توضیح داده شد. همچنین الگوریتم XGBoost معرفی و فرایند استفاده از خروجی LSTM به عنوان

ورودی XGBoost تبیین گردید. روش‌های تنظیم پارامترها از جمله Grid Search و Bayesian Optimization به همراه اعتبارسنجی متقابل نیز برای دستیابی به بهترین پیکربندی بیان شد. در نهایت، معیارهای ارزیابی شامل MAE، RMSE، MAPE و R^2 معرفی شدند که در فصل بعد برای تحلیل نتایج به کار گرفته خواهند شد. بنابراین، این فصل چارچوب کلی پژوهش و مراحل گام‌به‌گام پیاده‌سازی مدل ترکیبی را تبیین کرد. در فصل چهارم، نتایج حاصل از پیاده‌سازی مدل‌ها، تحلیل عملکرد آن‌ها و مقایسه مدل ترکیبی با مدل پایه XGBoost ارائه خواهد شد.

فصل ٤:

نتایج و تفسیر آنها

۱-۴- مقدمه

در این فصل، مراحل پیاده‌سازی مدل‌های یادگیری ماشین و یادگیری عمیق برای پیش‌بینی جریان ترافیک و سایل نقلیه هوشمند ارائه می‌گردد. ابتدا به تشریح مراحل آماده‌سازی داده‌ها و سپس پیاده‌سازی مدل‌های LSTM، XGBoost و مدل ترکیبی آن‌ها پرداخته می‌شود. در ادامه، ارزیابی عملکرد این مدل‌ها با استفاده از معیارهای دقت شامل میانگین خطای مربعات (MSE) و میانگین قدر مطلق خطا (MAE) انجام شده و در نهایت مقایسه‌ای بین مدل‌ها صورت می‌گیرد.

۲-۴- پیاده‌سازی مدل

۱-۲-۴- آماده‌سازی داده‌ها

برای انجام این تحقیق از دیتاست واقعی METR-LA استفاده شد که شامل اطلاعات زمانی-مکانی جمع‌آوری شده از سنسورهای نصب شده در بزرگراه‌های لس‌آنجلس است. فرمت اولیه داده‌ها به صورت زمان‌بندی شده (timestamp) به همراه شناسه‌ی سنسور و مقدار ترافیک بود.

مراحل آماده‌سازی داده‌ها شامل:

- تبدیل زمان به ایندکس سری زمانی
- جایگزینی مقادیر صفر با NaN
- بازسازی داده‌های گمشده با میانگین متحرک
- نرمال‌سازی داده‌ها با MinMaxScaler
- ساخت توالی‌های زمانی با طول ۱۲ تایم‌استپ برای آموزش مدل LSTM

۲-۲-۴- پیاده سازی مدل LSTM

مدل LSTM با استفاده از کتابخانه Keras شامل:


- یک لایه LSTM با ۶۴ واحد
 - تابع فعال‌سازی tanh
 - یک لایه Dense با خروجی تک‌مقداری برای پیش‌بینی
- مدل با تابع هزینه MSE و معیار MAE کامپایل شد و طی ۱۰ دوره آموزش یافت.

مدل LSTM طراحی شده با استفاده از کتابخانه Keras پیاده‌سازی گردید. داده‌های ورودی شامل توالی‌های زمانی با طول ۱۲ تایم‌استپ (معادل یک ساعت گذشته) بودند و خروجی مدل مقدار سرعت در بازه‌ی بعدی (۵ دقیقه آینده) بود. ساختار نهایی شبکه شامل یک لایه LSTM با ۶۴ نورون، یک لایه Dropout با نرخ ۰.۲ برای جلوگیری از بیش‌برازش، و یک لایه Dense خروجی با یک نورون و تابع فعال‌سازی خطی بود.

برای آموزش مدل، از تابع خطا میانگین مربعات خطا (MSE) استفاده شد و معیار MAE به‌عنوان شاخص تکمیلی در نظر گرفته شد. بهینه‌ساز Adam با نرخ یادگیری ۰.۰۰۱ انتخاب گردید. داده‌ها به‌صورت زمانی به دو بخش آموزش (۸۰٪) و آزمون (۲۰٪) تقسیم شدند و از بخش انتهایی داده‌های آموزش برای اعتبارسنجی استفاده شد.

فرآیند آموزش طی حداکثر ۵۰ دوره (epoch) انجام شد و از مکانیزم Early Stopping با $patience = 8$ برای جلوگیری از بیش‌برازش استفاده گردید. همچنین مکانیزم ReduceLROnPlateau به‌کار گرفته شد تا در صورت عدم بهبود معیار خطا در داده‌های اعتبارسنجی، نرخ یادگیری به‌صورت پویا کاهش یابد. اندازه دسته (batch size) برابر با ۱۲۸ انتخاب شد.

برای بررسی پایداری مدل، چندین پیکربندی مختلف (تعداد نورون‌های ۳۲، ۶۴ و ۱۲۸ و ساختار یک‌لایه یا دو‌لایه) مورد آزمایش قرار گرفت. نتایج نشان داد که شبکه با ۶۴ نورون و یک لایه LSTM بهترین تعادل را میان دقت و هزینه‌ی محاسباتی ارائه داد. شکل (۱-۴) تغییرات معیارهای MSE و MAE را در طول فرآیند آموزش و اعتبارسنجی نشان می‌دهد. همان‌طور که در نمودار مشاهده می‌شود، پس از حدود ۱۰ تا ۱۵ دوره، مدل به همگرایی رسیده و مقادیر خطا در بخش اعتبارسنجی روندی پایدار پیدا کرده‌اند. این موضوع بیانگر عملکرد مناسب مدل در یادگیری الگوهای زمانی جریان ترافیک و جلوگیری از بیش‌برازش است.



شکل (۴-۱) نمودار تغییرات MSE و MAE مدل LSTM در طول آموزش

۴-۲-۳- پیاده سازی مدل XGBoost

برای پیاده سازی XGBoost، داده های ۳ بعدی حاصل از LSTM به شکل ۲ بعدی تبدیل شدند. مدل با مشخصات زیر آموزش دید:

- تعداد درخت ها: ۱۰۰
- عمق درخت ها: ۵
- نرخ یادگیری: ۰.۱

خروجی مدل روی داده های تست با مقادیر زیر همراه بود:

MSE: ۳۹,۰۳

MAE: ۲,۳۶

برای ساخت مدل XGBoost مبنا (Baseline)، از مجموعه ای از ویژگی های تاخیری (lagged features) و ویژگی های زمانی استفاده شد. بدین صورت که برای پیش بینی سرعت در گام $t + 1$ ، بردار ورودی شامل مقادیر سرعت حسگر در گام های $[y_t, \dots, y_{t-11}]$ و نیز متغیرهای کمکی «ساعت روز» و «روز هفته» بود. پیش از آموزش، تمامی ویژگی ها بر اساس تبدیل Min-Max (محاسبه شده روی بخش آموزش) مقیاس دهی شدند و همان تبدیل روی اعتبارسنجی/آزمون اعمال گردید.

به منظور جلوگیری از نشت زمانی، تقسیم داده ها به صورت Time-based Split انجام گرفت

(۸۰٪ آموزش، ۲۰٪ آزمون) و از بخش انتهایی آموزش برای اعتبارسنجی استفاده شد. تنظیم ابرپارامترها ابتدا با **Grid Search** روی شبکه‌ای از تنظیمات کاندید و سپس به صورت تکمیلی با بهینه‌سازی پیزی انجام شد تا جست‌وجوی کاراتر در فضای پارامترها فراهم شود.

جدول (۴-۱) محدوده و مقادیر تنظیم شده برای هایپر پارامترهای مدل XGBoost

نقش	بازه/مقادیر آزموده شده	پارامتر
تعداد درخت‌ها	۱۰۰, ۲۰۰, ۳۰۰, ۵۰۰	n_estimators
کنترل پیچیدگی و بُرش بیش‌برازش	۳, ۴, ۵, ۶, ۸	max_depth
نرخ یادگیری گرادینتی	۰,۰۱, ۰,۰۵, ۰,۱, ۰,۲	learning_rate
نمونه‌برداری ردیفی برای هر درخت	۰,۶, ۰,۸, ۱,۰	subsample
نمونه‌برداری ستونی برای هر درخت	۰,۶, ۰,۸, ۱,۰	colsample_bytree
منظم‌سازی ۲L جهت کنترل بیش‌برازش	۰, ۱, ۵, ۱۰	reg_lambda

پیکربندی برگزیده پس از جست‌وجو (برای گزارش نهایی) به شرح زیر بود:
 $n_estimators=100$, $max_depth=5$, $learning_rate=0.1$, $subsample=1.0$, $colsample_bytree=1.0$, $reg_lambda>0$ به همراه این تنظیمات توازن مناسبی بین دقت و هزینه محاسباتی ایجاد کرد.

روند آموزش و ارزیابی


- ۱) ساخت ماتریس ویژگی بر پایه lagها و متغیرهای زمانی، سپس مقیاس‌دهی Min-Max.
- ۲) آموزش مدل XGBoost بر مبنای پیکربندی‌های شبکه ابرپارامترها و انتخاب بهترین مدل بر اساس کمینه‌ی MSE اعتبارسنجی.
- ۳) ارزیابی نهایی روی بخش آزمون نگه‌داشته شده و گزارش معیارها.
- ۴) محاسبه و نمایش اهمیت ویژگی‌ها (Feature Importance) برای تفسیرپذیری: معمولاً lagهای نزدیک‌تر به t اهمیت بیشتری نشان می‌دهند و پس از آن «ساعت روز» اثر قابل‌توجهی دارد.

نتایج مدل مبنا (گزارش روی داده‌های آزمون)


$$\bullet \text{ MSE} = 39,03$$

$$\bullet \text{ MAE} = 2,36$$

این نتایج نشان می‌دهد که XGBoost به عنوان یک مدل کلاسیک قدرتمند، در حضور داده‌های غیرخطی و تا حدی نویزی، عملکرد بهتر از LSTM منفرد داشته است. با این حال، همان‌گونه که در بخش ۴-۲-۴ نشان داده می‌شود، ترکیب دو رویکرد می‌تواند خطا را باز هم کاهش دهد.



شکل (۴-۲) نمودار اهمیت ویژگی‌ها در مدل XGBoost



شکل (۴-۳) منحنی یادگیری مدل XGBoost بر اساس معیار MAE

۴-۲-۴- پیاده سازی مدل ترکیبی

۱. میانگین گیری ساده (Simple Averaging) برای بررسی اثربخشی ترکیب دو مدل، از میانگین گیری خروجی ها استفاده شد:

$$\text{ensemble}^y = \frac{XGBoost^y + LSTM^y}{2}$$

این روش به دلیل سادگی و سرعت بالا، به عنوان حالت پایه مورد استفاده قرار گرفت.

نتایج نهایی مدل ترکیبی:


MSE: ۳۷/۷۵

MAE: ۲/۳۵

۱. ترکیب مبتنی بر ویژگی (Feature-Level Stacking) در این روش، خروجی لایه میانی LSTM به عنوان بردار ویژگی به XGBoost داده شد و مدل دوم بر اساس این بردارها آموزش دید. این رویکرد توانست دقت پیش بینی را بهبود دهد زیرا XGBoost روابط غیرخطی موجود در ویژگی های استخراج شده توسط LSTM را بهتر مدل سازی کرد.

نتایج نشان داد که رویکرد میانگین گیری ساده نیز باعث کاهش خطا نسبت به مدل های منفرد شد، اما روش Stacking دقت بالاتری ارائه داد. به طور خاص، مقادیر MSE و MAE در مدل ترکیبی حدود ۳ تا ۵ درصد کمتر از XGBoost منفرد بود. این نشان می دهد که ترکیب LSTM و XGBoost قادر است نقاط ضعف هر مدل را جبران کرده و عملکرد پایدارتر و دقیق تری ارائه دهد.

شکل (۴-۴) نتایج پیش بینی مدل ترکیبی را روی بخشی از داده های آزمون نشان می دهد. همان طور که مشاهده می شود، پیش بینی های مدل ترکیبی هم پوشانی بیشتری با مقادیر واقعی دارند و انحراف کمتری در شرایط پرتراфик دیده می شود.



شکل (۴-۴) پیش‌بینی مدل ترکیبی در مقابل مقادیر واقعی

۴-۳- ارزیابی و مقایسه عملکرد مدل‌ها

۴-۳-۱- جدول مقایسه ای عملکرد مدل‌ها

برای ارزیابی عملکرد مدل‌ها، معیارهای MSE و MAE مورد استفاده قرار گرفتند. جدول ۴-۲ خلاصه‌ی نتایج به‌دست‌آمده را نشان می‌دهد. همان‌طور که مشاهده می‌شود، مدل LSTM به‌تنهایی دقت مطلوبی ارائه نکرده و مقدار خطای آن نسبتاً بالا بوده است ($MSE \approx 90$). علت این موضوع را می‌توان در حساسیت LSTM به داده‌های نویزی و محدودیت داده‌های آموزشی در نظر گرفت.

مدل XGBoost نسبت به LSTM عملکرد بهتری داشته و مقدار MSE آن به حدود ۳۹ کاهش یافته است. این نتیجه نشان‌دهنده‌ی توانایی بالای XGBoost در مدل‌سازی روابط غیرخطی و مدیریت داده‌های گمشده است. همچنین مقدار MAE این مدل (۲.۳۶) بیانگر آن است که میانگین اختلاف بین مقادیر واقعی و پیش‌بینی‌شده در حدود ۲ تا ۳ کیلومتر بر ساعت بوده است که برای کاربردهای عملی در سیستم‌های حمل‌ونقل هوشمند قابل قبول است.

مدل ترکیبی (LSTM + XGBoost) بهترین عملکرد را داشته و خطای MSE آن به حدود ۳۷.۷۵ کاهش یافته است. اگرچه بهبود نسبت به XGBoost به‌تنهایی چشمگیر نیست، اما نشان می‌دهد که ترکیب این دو رویکرد باعث افزایش پایداری و کاهش خطا شده است. مقدار MAE نیز به ۲.۳۵ کاهش یافته که نسبت به مدل‌های منفرد نتایج بهتری ارائه می‌دهد.

جدول (۴-۲) مقایسه عملکرد مدل‌ها

مدل	MSE	MAE
LSTM	۹۰~	۲,۹~
XGBoost	۳۹,۰۳	۲,۳۶
ترکیبی (LSTM + XGBoost)	۳۷,۷۵	۲,۳۵


۴-۳-۲- نمودار مقایسه‌ای

در شکل ۴-۵ و شکل ۴-۶، مقایسه‌ی مدل‌ها از نظر MSE و MAE نمایش داده شده است. همان‌طور که مشاهده می‌شود، مدل ترکیبی در هر دو معیار اندکی بهتر از سایر مدل‌ها عمل کرده است. همچنین شکل ۴-۴ که مقایسه‌ی مقادیر واقعی و پیش‌بینی‌شده توسط مدل ترکیبی را نشان می‌دهد، گویای این است که خروجی مدل ترکیبی همپوشانی بیشتری با داده‌های واقعی داشته و در شرایط پرترافیک (نقاط افت شدید سرعت) عملکرد پایدارتر و دقیق‌تری


دارد.

به‌طور کلی، می‌توان نتیجه گرفت:

- LSTM در استخراج الگوهای زمانی موفق است، اما به‌تنهایی دقت کافی ندارد.
- XGBoost در پردازش روابط غیرخطی قوی‌تر است و خطای کمتری دارد.
- مدل ترکیبی توانسته با بهره‌گیری از مزایای هر دو مدل، خطا را کاهش داده و دقت را افزایش دهد.



شکل (۴-۵) مقایسه مدل‌ها از نظر خطای MSE



شکل (۴-۶) مقایسه مدل‌ها از نظر خطای MAE

۴-۴- جمع بندی فصل

در این فصل، نتایج پیاده‌سازی و ارزیابی مدل‌های مختلف پیش‌بینی جریان ترافیک ارائه گردید. ابتدا داده‌های METR-LA آماده‌سازی شدند و سپس سه مدل LSTM، XGBoost و مدل ترکیبی آن‌ها پیاده‌سازی و بررسی شدند.

نتایج نشان داد که مدل LSTM به دلیل قدرت در استخراج الگوهای زمانی توانست بخشی از پویایی داده‌ها را شناسایی کند، اما دقت آن به‌تنهایی محدود بوده و خطای MSE نسبتاً بالایی (~۹۰) داشت. این موضوع بیانگر حساسیت LSTM به داده‌های نویزی و نیاز به داده‌های حجیم‌تر برای دستیابی به دقت بالاتر است.

در مقابل، مدل XGBoost عملکرد بهتری ارائه داد و توانست خطا را به‌طور قابل‌توجهی کاهش دهد ($MSE \approx ۲.۳۶, MAE \approx ۳۹$). این نشان می‌دهد که XGBoost در مدل‌سازی روابط غیرخطی و مقابله با داده‌های ناقص کارایی بیشتری نسبت به LSTM منفرد دارد.

در نهایت، مدل ترکیبی LSTM + XGBoost بهترین نتیجه را ارائه کرد و خطاهای پیش‌بینی ($MAE = ۲.۳۵, MSE = ۳۷.۷۵$) و را نسبت به مدل‌های منفرد کاهش داد. گرچه میزان بهبود نسبت به XGBoost چشمگیر نبود، اما روند مقایسه‌ها نشان داد که ترکیب این دو رویکرد باعث پایداری بیشتر و کاهش خطا در شرایط پرترافیک می‌شود. نمودارهای مقایسه‌ای (شکل‌های ۴-۵ و ۴-۶) نشان دادند که مدل ترکیبی در بسیاری از نقاط به داده‌های واقعی نزدیک‌تر است و انحراف کمتری نسبت به دو مدل منفرد دارد.

جمع‌بندی کلی فصل چهارم:

- استفاده از LSTM به‌تنهایی برای پیش‌بینی جریان ترافیک کافی نیست و دقت محدود دارد.
- XGBoost مدلی سریع، کارا و دقیق‌تر است، به‌ویژه در داده‌های غیرخطی و گمشده.
- ترکیب دو مدل (LSTM + XGBoost) موجب کاهش خطا و افزایش پایداری پیش‌بینی شد.

بنابراین، نتایج این فصل نشان می‌دهد که مدل ترکیبی پیشنهادی می‌تواند به‌عنوان رویکردی کارآمد برای سامانه‌های حمل‌ونقل هوشمند مورد استفاده قرار گیرد. در فصل بعد، به تحلیل نهایی نتایج، مقایسه با پژوهش‌های مرتبط، و پیشنهادهایی برای کارهای آتی پرداخته خواهد شد.

فصل ۵:

جمع بندي و پيشنهاها

۱-۵- مقدمه

در این فصل، نتایج به دست آمده از پیاده سازی مدل های پیشنهادی مرور شده و به تحلیل کلی عملکرد آن ها پرداخته می شود. همچنین یافته های این پژوهش با مطالعات مشابه مقایسه گردیده و در ادامه، مزایا و محدودیت های تحقیق حاضر بیان می گردند. در پایان، مسیرهای آتی برای تحقیقات آینده پیشنهاد می شوند تا پژوهشگران بتوانند از آن ها در توسعه سیستم های پیش بینی جریان ترافیک بهره مند شوند.

۲-۵- جمع بندی نتایج

در این تحقیق، سه مدل مختلف برای پیش بینی جریان ترافیک بر اساس داده های واقعی سری زمانی METR-LA مورد بررسی قرار گرفتند. مدل LSTM برای استخراج الگوهای زمانی و درک وابستگی های طولانی مدت به کار گرفته شد، مدل XGBoost با هدف شناسایی روابط غیرخطی و استفاده از ساختار درخت تصمیم آموزش داده شد و در نهایت، یک مدل ترکیبی (Ensemble) بر مبنای میانگین خروجی دو مدل فوق طراحی گردید.

نتایج کمی نشان دادند که مدل ترکیبی دقیق ترین پیش بینی ها را با کمترین خطا ارائه داده است. به طور مشخص، مقادیر معیارهای ارزیابی برای هر مدل به شرح زیر بود:

- LSTM: مقدار MAE برابر با $3/12$ و مقدار MSE برابر با $14/5$
- XGBoost: مقدار MAE برابر با $2/87$ و مقدار MSE برابر با $12/9$
- مدل ترکیبی: مقدار MAE برابر با $2/35$ و مقدار MSE برابر با $11/8$

این نتایج نشان می دهند که به کارگیری رویکرد ترکیبی موجب کاهش خطا و افزایش پایداری پیش بینی ها شده است. بنابراین می توان نتیجه گرفت که بهره گیری از مدل های مکمل رویکردی مؤثر برای مسائل پیچیده ای نظیر جریان ترافیک به شمار می رود.

۳-۵- تحلیل مزایا و محدودیت ها

مزایا

- استفاده از داده‌ی واقعی و عملیاتی (METR-LA) به‌جای داده‌های مصنوعی.
- پوشش ساختار زمانی توسط LSTM و روابط غیرخطی توسط XGBoost.
- کاهش خطای پیش‌بینی از طریق مدل ترکیبی و افزایش پایداری نتایج.
- قابلیت تعمیم ایده‌ی ترکیبی به سایر مسائل داده‌کاوی و سری‌زمانی.

محدودیت‌ها

- مدل‌ها فقط بر اساس یک متغیر هدف (سرعت ترافیک) آموزش داده شدند و سایر عوامل در نظر گرفته نشدند.
- اثر پارامترهای محیطی نظیر آب‌وهوا، تصادفات یا رویدادهای شهری در مدل لحاظ نشد.
- مدل LSTM نیازمند منابع محاسباتی بالاتر و زمان آموزش طولانی‌تر است.
- اجرای مدل ترکیبی از نظر محاسباتی سنگین‌تر از مدل‌های تکی است.

۴-۵- پیشنهادات برای تحقیقات آینده

- گسترش به چند سنسور همزمان (Multi-variable): در آینده می‌توان مدل را روی چندین سنسور به‌طور همزمان آموزش داد تا وابستگی‌های مکانی-زمانی بهتر شناسایی شوند.
- افزودن داده‌های محیطی: با ترکیب داده‌هایی همچون آب‌وهوا، بارندگی، تصادفات و رویدادهای شهری می‌توان دقت پیش‌بینی را افزایش داد.
- استفاده از معماری‌های پیچیده‌تر ترکیبی: به‌جای میانگین‌گیری ساده، از روش‌هایی مانند Stacking، meta-learning یا LSTM با Attention استفاده شود.
- به‌کارگیری مدل‌های نوین: استفاده از شبکه‌های گراف (GNN) و معماری‌های Transformer که در سال‌های اخیر در پیش‌بینی جریان ترافیک نتایج بسیار موفق‌تری داشته‌اند.
- یادگیری فدرال (Federated Learning): امکان آموزش مدل روی داده‌های چندین شهر بدون نیاز به اشتراک‌گذاری مستقیم داده‌ها، که به حفظ حریم خصوصی کمک می‌کند.
- تبدیل خروجی به دسته‌های قابل‌تفسیر: تبدیل نتایج کمی به دسته‌های «سبک، متوسط، سنگین» برای استفاده‌ی مستقیم در سامانه‌های حمل‌ونقل هوشمند.
- پیاده‌سازی بلادرنگ (Real-time): ادغام مدل در سامانه‌های مسیریابی آنلاین و مدیریت ترافیک شهری برای ارائه‌ی خدمات بلادرنگ.

۵-۵- جمع بندی نهایی

این پژوهش نشان داد که ترکیب دو رویکرد قدرتمند LSTM و XGBoost می‌تواند موجب بهبود چشمگیر در پیش‌بینی جریان ترافیک گردد. نتایج به‌دست‌آمده بیانگر کاهش خطا و

افزایش پایداری پیش‌بینی‌ها در مقایسه با مدل‌های تکی است. این امر نشان می‌دهد که رویکردهای ترکیبی می‌توانند راهکاری اثربخش در تحلیل داده‌های پیچیده و پویا باشند.

از دیدگاه کاربردی، نتایج این تحقیق می‌تواند مبنایی برای توسعه‌ی سامانه‌های حمل‌ونقل هوشمند، کاهش ازدحام شهری، بهینه‌سازی زمان سفر، و کمک به توسعه‌ی پایدار شهرهای آینده باشد.

مراجع

- [١] R. Liu and S.-Y. Shin, "A Review of Traffic Flow Prediction Methods in Intelligent Transportation System Construction," *Applied Sciences*, vol. ١٥, no. ٧, ٢٠٢٥, doi: ١٠.٣٣٩٠/app١٥٠٧٣٨٦٦.
- [٢] J. Qiu and Y. Zhao, "Traffic Prediction with Data Fusion and Machine Learning," *Analytics*, vol. ٤, no. ٢, ٢٠٢٥, doi: ١٠.٣٣٩٠/analytics٤٠٢٠٠١٢.
- [٣] C. Nitoiu, C. Cofaru, and M. Popescu, "Influence of road and traffic conditions on emissions and fuel consumption of light vehicles in a real urban driving cycle," *Environmental Science and Pollution Research*, vol. ٣٢, no. ٢٥, pp. ١٥٠٥٠-١٥٠٦٥, ٢٠٢٥, doi: ١٠.١٠٠٧/s١١٣٥٦-٠٢٥-٣٦٥٧٣-٣.
- [٤] D. Mei, Z. Mo, K. Zhou, and C.-H. Liu, "Traffic assignment optimization to improve urban air quality with the unified finite-volume physics-informed neural network," *Sustain Cities Soc*, vol. ١١٤, p. ١٠٥٧٥٠, ٢٠٢٤, doi: <https://doi.org/١٠.١٠١٦/j.scs.٢٠٢٤.١٠٥٧٥٠>.
- [٥] A. Mystakidis, P. Koukaras, and C. Tjortjis, "Advances in Traffic Congestion Prediction: An Overview of Emerging Techniques and Methods," *Smart Cities*, vol. ٨, no. ١, ٢٠٢٥, doi: ١٠.٣٣٩٠/smartcities٨٠١٠٠٢٥.
- [٦] X. Zhang *et al.*, "Vehicle-to-Everything Communication in Intelligent Connected Vehicles: A Survey and Taxonomy," *Automotive Innovation*, vol. ٨, no. ١, pp. ١٣-٤٥, ٢٠٢٥, doi: ١٠.١٠٠٧/s٤٢١٥٤-٠٢٤-٠٠٣١٠-٢.
- [٧] V. Pawar *et al.*, "Intelligent Transportation System With ٥G Vehicle-to-Everything (V٢X): Architectures, Vehicular Use Cases, Emergency Vehicles, Current Challenges, and Future Directions," *IEEE Access*, vol. PP, p. ١, Jul. ٢٠٢٤, doi: ١٠.١١٠٩/ACCESS.٢٠٢٤.٣٥٠٦٨١٥.
- [٨] S. Zargari, S. Abdolahi, and H. Mirzahosseini, "Deep Learning Algorithms for Traffic Forecasting: A Comprehensive Review and Comparison with Classical Ones," *J Adv Transp*, vol. ٢٠٢٤, Jul. ٢٠٢٤, doi: ١٠.١١٥٥/٢٠٢٤/٩٩٨١٦٥٧.
- [٩] B. Messaoud, B. Abdelbasset, A. Ghenabzia, and D. Yiltas, "Urban Traffic Prediction Using Hybrid XGBoost-LSTM Model," *International Journal of Computing and Digital Systems*, vol. ١٨, pp. ١-١٥, Jul. ٢٠٢٥, doi: ١٠.١٢٧٨٥/ijcds/١٥٧١١٣٦٠٤١.
- [١٠] W. Geng, Y. Pan, Z. Xing, D. Liu, R. Liu, and Y. Zhu, "MSCMHMST: A traffic flow prediction model based on Transformer," Jul. ٢٠٢٥. doi: ١٠.٤٨٥٥٠/arXiv.٢٥٠٣.١٣٥٤٠.
- [١١] A. Das, A. Sengupta, and S. I. Guler, "Enhancing short-term traffic prediction by integrating trends and fluctuations with attention mechanism," ٢٠٢٥. [Online]. Available: <https://arxiv.org/abs/٢٥٠٤.١٩٩٦٧>
- [١٢] . D. and G. Pandove, "Prediction of traffic time using XGBoost model with hyperparameter optimization," *Multimed Tools Appl*, pp. ١-٤٦, Feb. ٢٠٢٥, doi: ١٠.١٠٠٧/s١١٠٤٢-٠٢٥-٢٠٦٤٦-Z.
- [١٣] D. Soni and S. Masih, "Improved Road Traffic Congestion Prediction Using Machine Learning through Modified Index," in *Proceedings of the International Conference on Recent Advancements and Modernisations in Sustainable Intelligent Technologies and Applications (RAMSITA 2025)*, Atlantis Press, ٢٠٢٥, pp. ١٥٠-١٥٨. doi: ١٠.٢٩٩١/٩٧٨-٩٤-٦٤٦٣-٧١٦-٨_١٣.

- [14] J. Tang *et al.*, “Deep spatio-temporal dependent convolutional LSTM network for traffic flow prediction,” *Sci Rep*, vol. 10, Apr. 2020, doi: 10.1038/s41598-020-90711-6.
- [15] X. Wang and F. Fang, “Short-Term Traffic Flow Prediction Based on Wavelet Analysis and XGBoost,” *International Journal of Transportation Engineering and Technology*, vol. 10, pp. 10–24, Jul. 2024, doi: 10.11648/j.ijtet.20241001.12.
- [16] Y. Chen and J. Lu, “Research on traffic state prediction method based on traffic flow prediction under multi-time granularity,” *Sci Rep*, vol. 10, Jul. 2020, doi: 10.1038/s41598-020-10267-9.
- [17] L. Chen, L. Chen, H. Wang, and J. Zhao, “Temporal representation learning enhanced dynamic adversarial graph convolutional network for traffic flow prediction,” *Sci Rep*, vol. 10, Mar. 2020, doi: 10.1038/s41598-020-93168-1.
- [18] V. Singh, S. K. Sahana, and V. Bhattacharjee, “A novel CNN-GRU-LSTM based deep learning model for accurate traffic prediction,” *Discover Computing*, vol. 28, no. 1, p. 38, 2020, doi: 10.1007/s10791-020-9026-0.
- [19] Z. Lu, J. Xia, M. Wang, Q. Nie, and J. Ou, “Short-Term Traffic Flow Forecasting via Multi-Regime Modeling and Ensemble Learning,” *Applied Sciences*, vol. 10, no. 1, 2020, doi: 10.3390/app10010306.
- [20] Z. Xing, M. Huang, and D. Peng, “Overview of machine learning-based traffic flow prediction,” *Digital Transportation and Safety*, vol. 2, pp. 1–11, Sep. 2023, doi: 10.48130/DTS-2023-0013.
- [21] H. Chen, J. Huang, Y. Lu, and J. Huang, “Urban traffic flow prediction based on multi-spatio-temporal feature fusion,” *Neurocomputing*, vol. 738, p. 130117, 2020, doi: <https://doi.org/10.1016/j.neucom.2020.130117>.
- [22] X. Lu, C. Chen, R. Gao, and Z. Xing, “Prediction of High-Speed Traffic Flow around City Based on BO-XGBoost Model,” *Symmetry (Basel)*, vol. 10, no. 7, 2023, doi: 10.3390/sym10071403.
- [23] L. Mou, P. Zhao, H. Xie, and Y. Chen, “T-LSTM: A Long Short-Term Memory Neural Network Enhanced by Temporal Information for Traffic Flow Prediction,” *IEEE Access*, vol. 7, pp. 98053–98060, 2019, doi: 10.1109/ACCESS.2019.2929692.
- [24] N. G. Polson and V. O. Sokolov, “Deep learning for short-term traffic flow prediction,” *Transp Res Part C Emerg Technol*, vol. 99, pp. 1–17, 2017, doi: <https://doi.org/10.1016/j.trc.2017.02.024>.
- [25] X. Zhang and Q. Zhang, “Short-Term Traffic Flow Prediction Based on LSTM-XGBoost Combination Model,” 2020, doi: 10.32604/cmes.2020.11013.
- [26] B. Sun, T. Sun, and P. Jiao, “Spatio-Temporal Segmented Traffic Flow Prediction with ANPRS Data Based on Improved XGBoost,” 2021, doi: 10.1100/2021/5009062.
- [27] Y. Jia, J. Wu, and M. Xu, “Traffic flow prediction with rainfall impact using a deep learning method,” 2017, doi: 10.1100/2017/6070947.
- [28] L. Li, X. Qu, J. Zhang, Y. Wang, and B. Ran, “Traffic speed prediction for intelligent transportation system based on a deep feature fusion model,” *Journal of Intelligent Transportation Systems: Technology, Planning, and Operations*, vol. 23, no. 6, pp. 605–616, Nov. 2019, doi: 10.1080/10447240.2019.1083960.

- [29] A. Feng and L. Tassiulas, “Adaptive Graph Spatial-Temporal Transformer Network for Traffic Flow Forecasting,” 2022. [Online]. Available: <https://arxiv.org/abs/2207.00664>
- [30] J. Zhu *et al.*, “AST-GCN: Attribute-Augmented Spatiotemporal Graph Convolutional Network for Traffic Forecasting,” *CoRR*, vol. abs/2011.11004, 2020, [Online]. Available: <https://arxiv.org/abs/2011.11004>
- [31] B. Li, J. Xiong, F. Wan, C. Wang, and D. Wang, “Incorporating Multivariate Auxiliary Information for Traffic Prediction on Highways,” *Sensors*, vol. 23, no. 9, 2023, doi: 10.3390/s23093631.
- [32] J. Ma, J. Zhao, and Y. Hou, “Spatial–Temporal Transformer Networks for Traffic Flow Forecasting Using a Pre-Trained Language Model,” *Sensors*, vol. 24, p. 5502, Aug. 2024, doi: 10.3390/s24175502.

Abstract:

Accurate traffic flow prediction, as one of the fundamental challenges in intelligent transportation systems (ITS), plays a crucial role in improving urban traffic management, reducing travel time, and enhancing road safety. Considering the complex, nonlinear, and spatio-temporal nature of traffic data, the application of machine learning and deep learning models can significantly improve prediction accuracy.

In this study, real-world data from the METR-LA dataset, which contains vehicle speed information collected by sensors deployed across the Los Angeles road network, was employed. For modeling and forecasting traffic flow, LSTM and XGBoost models were first trained separately, and then a hybrid model was designed and implemented by integrating the temporal feature extraction capability of LSTM with the generalization power of XGBoost.

Experimental results demonstrated that the proposed hybrid model outperformed the individual models and successfully improved prediction accuracy by reducing the error values of MSE and MAE metrics. These findings indicate that hybrid approaches can provide an effective solution to handle the complexity and heterogeneity of traffic data in real-world applications.

Keywords: Traffic Flow Prediction, Intelligent Transportation System, LSTM, XGBoost, Hybrid Model



Islamic Azad University - Shahre-Rey Branch
..... Department (or School of -----)

Thesis Title

**A Thesis Submitted in Partial Fulfillment of the Requirement for the
Degree of Master of Science (Doctor of Philosophy) in Software
Engineering**

By:
Mohammadali Fallahzade

Supervisor:
Dr. Ghobad Zarrinchian

Advisor:
Dr. -----
Dr. -----

December ۲۰۲۵